# Agentic RL 算法与关键技术

**研究范围**：基于 47 篇 Agentic RL 论文（2024-2026 Q1）的系统性分析
**侧重点**：有影响力的算法的**设计动机**与**面临的挑战**
**关联**：基础算法（GRPO/DAPO/VAPO/CISPO/GSPO/SAPO）的详细推导参见 Post-Training 报告第一章

---

**目录**


- 一、从推理 RL 到 Agentic RL：问题的本质变化
- 二、奖励信号：从稀疏到自包含
- 三、训练稳定性：从经验到收敛保证
- 四、探索效率：突破 On-Policy 局限
- 五、信用分配：长程归因的精细化
- 六、Agentic 工程实践
- 七、算法速查与对比


---

## 一、从推理 RL 到 Agentic RL：问题的本质变化

### 1.1 RLVR 的成功与边界

2025 年，RLVR（基于可验证奖励的强化学习）在推理任务上取得了突破性成功。GRPO（arXiv: 2501.12948）消除了 Critic 网络，DAPO（arXiv: 2503.14476）解决了工程稳定性，VAPO（arXiv: 2504.05118）修复了 Value 估计——这些算法在数学、代码等**单轮可验证任务**上已经高度成熟。

但 RLVR 的成功建立在两个隐含假设上：

1. **奖励可验证**：答案有确定的对/错判定（数学答案、代码测试用例）
2. **单轮决策**：模型生成一个完整回复，获得一次奖励反馈

当任务变为**多轮交互**（搜索 → 分析 → 决策 → 执行）、**工具使用**（调用 API、操作环境）、**长程规划**（数十步才有最终结果）时，这两个假设同时失效。这就是 Agentic RL 面临的根本挑战。

### 1.2 Agentic RL 的核心矛盾

Agent 任务的**长程性**、**开放性**、**交互性** vs RL 算法对**短程**、**可验证**、**单步决策**的假设

| Agent 任务特征 | RL 算法假设 | 产生的挑战 |
|---|---|---|
| 长程推理（数百步） | 短程决策（10-100 步） | 信用分配困难、方差爆炸 |
| 开放式目标 | 可验证奖励 | 奖励稀疏、难以设计 |
| 多轮环境交互 | 单步反馈 | 延迟反馈、归因不清 |
| 巨大动作空间（语言 + 工具） | 小动作空间 | 探索低效 |

### 1.3 四大核心挑战

基于 47 篇论文的统计分析，Agentic RL 面临四大核心挑战：

| 挑战 | 论文提及频率 | 本质 |
|---|---|---|
| **奖励信号质量** | 68% | 如何在长程交互中获得高质量学习信号 |
| **训练稳定性** | 53% | 如何控制长序列带来的梯度方差爆炸 |
| **探索效率** | 44% | 如何在巨大的语言动作空间中高效探索 |
| **信用分配** | 44% | 如何将最终奖励归因到每个决策步骤 |

这四个挑战并非独立——奖励信号是**源头**（稀疏/噪声导致方差爆炸），信用分配是**桥梁**（精确归因能改善奖励质量），训练稳定性是**保障**，探索效率是**最终目标**：

```
奖励信号质量（源头）
    ↓ 稀疏/噪声 → 方差爆炸
训练稳定性 ↔ 信用分配（桥梁）
    ↓ 不稳定 → 限制探索
探索效率（最终目标）
```

---

## 二、奖励信号：从稀疏到自包含

### 2.1 问题分析

Agentic 任务中，奖励信号面临三重困境：

- **稀疏奖励**（16/47 篇提及）：Agent 经过数十步交互后才获得成/败信号，中间步骤无反馈
- **噪声奖励**（4 篇）：使用外部 Reward Model 评估开放式任务时，RM 本身不够准确
- **Advantage Collapse**（3 篇）：GRPO 的组内归一化在全组获得相同 reward 时，advantage 退化为零，梯度消失

**初学者补充**：推理 RL（如 DeepSeek-R1）的奖励是「答案是否正确」——这是一个**二值信号**，清晰且可靠。但 Agent 任务（如「帮我调研某个话题并写一份报告」）的「正确」标准模糊得多，如何给这类任务打分是一个开放问题。

### 2.2 IGPO —信息增益作为内在奖励

**Paper**: Information Gain-based Policy Optimization (arXiv: 2510.14967) | **机构**：阿里巴巴

**设计动机**：多轮搜索/交互任务中，最终答案的对/错无法区分每一轮交互的贡献。一次有效的搜索操作和一次无效的搜索操作在 Outcome Reward 下看起来完全一样。IGPO 的核心问题是：**能否用模型自身的"信心变化"作为奖励信号，完全不依赖外部 RM?**

**核心方法**：在每一轮交互 $t$，计算模型产生正确答案的概率。Turn-level 奖励定义为**该概率相对于上一轮的边际增加量**：- 如果本轮搜索让模型对正确答案更有信心 $\rightarrow$ 正奖励 - 如果本轮搜索没有帮助或造成干扰 $\rightarrow$ 负奖励

这本质上是一种**内在奖励**（intrinsic reward），完全从模型自身的 belief update 中推导，不需要任何外部标注或奖励模型。

**关键创新**：同时解决了两个问题——(1) 奖励稀疏：每轮都有信号；(2) Advantage Collapse：不同轮次的信息增益天然不同。

**面临的挑战**：- 仍需要**最终答案可验证**（需要知道正确答案来计算概率），对完全开放式任务不适用 - 计算每轮条件概率需要额外的 forward pass，增加训练开销 - 模型的"信心"不总是与真实准确性一致（校准问题）

### 2.3 CM2 —多维度 Checklist 奖励

**Paper**: Checklist Rewards for Multi-turn Tool-use (arXiv: 2602.12268) | **机构**：字节跳动 | **已开源**

**设计动机**：单一标量奖励无法区分 Agent 行为的多个维度。一个 Agent 可能正确选择了工具但参数传错了，也可能工具选错了但格式完美——标量奖励无法捕捉这种差异。

**核心方法**：设计 7 个细粒度评估组件，为每轮交互提供多维度密集反馈。Checklist 涵盖工具选择准确性、参数正确性、输出格式、任务进展等维度，每个维度独立评分。

**面临的挑战**：- Checklist 的设计高度**任务特定**，换一个任务域就需要重新设计评估维度 - 维度之间的权重平衡缺乏理论指导 - 评估维度越多，标注/自动评估的成本越高

### 2.4 其他方案概览

| 算法 | arXiv | 核心思路 | 适用场景 |
|---|---|---|---|
| **EDGE-GRPO** | 2507.21848 | 引入熵项打破组内相同 reward 导致的 advantage=0 | Advantage Collapse |
| **ReGFT** | 2603.01223 | 提供部分人工参考解法作为 hint，引导模型生成它原本无法独立生成的正确轨迹 | 困难问题冷启动（本质是 SFT 而非 RL） |

| 算法 | arXiv | 核心思路 | 适用场景 |
|---|---|---|---|
| **PF-PPO** | 2409.06957 | 基于 RM 不确定性过滤不可靠样本，只用高置信度奖励训练 | 噪声 RM 场景 |
| **ZeroSearch** | 2505.04588 | 用 LLM 模拟搜索引擎，避免真实 API 的噪声文档 | 搜索增强任务 |
| **DARS** | 2508.13755 | 多阶段 rollout 采样，为低准确度困难问题动态分配更多 rollouts | 困难样本欠采样 |

---

## 三、训练稳定性：从经验到收敛保证

### 3.1 问题分析

Agentic 任务的长序列和多轮交互引发严重的训练不稳定：

- **IS ratio 极端化**（6 篇）：长序列中，token-level importance sampling 权重容易溢出，导致更新失控
- **Outlier tokens**（4 篇）：个别 token 的极端奖励主导整个更新方向
- **Value 估计偏差**（3 篇）：Value network 在长 CoT 中不准确，导致 advantage 错误
- **多轮 RL 不收敛**：传统算法（PPO、GRPO）在多轮任务上**缺乏收敛保证**

**初学者补充**：Importance Sampling (IS) ratio 是 $\pi_\theta(a|s)/\pi_{\text{old}}(a|s)$，衡量新旧策略的差异。在长序列中，每个 token 的 IS ratio 相乘后可能变得极大或极小，这就是为什么长序列 RL 比短序列难得多。

### 3.2 SeeUPO —首个多轮 RL 收敛保证

> **Paper**: Sequence-Level Sequential Update with Convergence Guarantee (arXiv: 2602.06554) | **机构**: 阿里巴巴 | **ICLR 2026**

**设计动机**：SeeUPO 的出发点是一个**理论层面的发现**——它证明了传统算法（PPO、GRPO）在 multi-turn 任务上存在一个根本性的矛盾：**无 Critic（GRAE）和训练收敛不可得兼**。

具体来说：- Value-Free 算法（GRPO 类）无法区分多轮中各轮的贡献 → 梯度有偏 → 不收敛 - 即使用 Critic（PPO 类），在多轮中 Value 估计误差累积也会导致偏差

这意味着**直接把单轮 RL 算法搬到多轮场景，理论上就不对**。

**核心方法**：SeeUPO 将 multi-turn 交互重新建模为**多个 Agent 的顺序决策问题**——第 1 轮的行为由 Agent 1 决定，第 2 轮由 Agent 2 决定...然后通过 **backward induction**（反向逐轮更新策略），从最后一轮倒推回第一轮，保证**单调改进**和**全局最优收敛**。

直觉上，这类似于博弈论中的逆向归纳：先想清楚最后一步应该怎么做，再基于此推导倒数第二步...直到第一步。

**关键成果**：AppWorld +43.3%, BFCL +24.1%。这是**首个理论上证明 multi-turn RL 可收敛到全局最优**的算法。

**面临的挑战**：- Backward induction 需要**逐轮更新**，训练开销随轮次线性增长 - "多 Agent 建模"假设各轮相对独立，但实际上各轮之间有复杂依赖 - 收敛保证依赖于采样质量，实际中有限采样可能偏离理论条件 - 目前仅在对话式任务上验证，对超长步骤的 Agent 任务（如软件工程）的适用性未知

### 3.3 ARLArena/SAMPO —系统性稳定性分析框架

> **Paper**: Unified Framework for Stable Agentic RL (arXiv: 2602.21534) | **机构**: UCLA

**设计动机**：Agentic RL 训练频繁崩溃，但社区对不稳定性的来源缺乏系统性理解。不同论文各自修补一个问题（IS clipping、advantage 归一化、loss 聚合...），但没有人从全局视角分析：**哪些因素真正导致崩溃，哪些改进是关键的，哪些是无关紧要的？**

**核心方法**：ARLArena 将 Policy Gradient 算法分解为四个正交维度进行系统测试：

1. **IS Clipping**：如何限制 importance sampling 权重（token-level vs sequence-level，裁剪范围）
2. **Dynamic Filtering**：如何过滤极端样本（基于 reward、advantage、trajectory 质量）
3. **Advantage Assignment**：如何计算优势函数（token-level vs step-level vs trajectory-level）

4. **Loss Aggregation**: 如何聚合多个 token/step 的 loss

通过控制变量实验，ARLArena 发现了训练崩溃的根本原因：**负优势 + 宽松 IS 裁剪轨迹的累积**。具体来说，当一条轨迹获得负 advantage 但 IS ratio 因裁剪范围过宽没被有效限制时，这条轨迹会产生过大的负梯度，多条这样的轨迹累积就导致崩溃。

基于分析，ARLArena 提出 **SAMPO**（Stable Agentic Policy Optimization）配置，在四个维度上选择最稳定的组合。

**面临的挑战**：- 框架是**描述性**的（告诉你什么组合稳定），不是**规范性**的（无法预测新场景的最优配置）- 最优配置可能随模型规模、任务类型变化 - 四个维度的交互效应复杂，全组合搜索成本高

### 3.4 VCPO —方差控制的动态学习率

**Paper**: Variance-Controlled Off-Policy RL (arXiv: 2602.17616) | **机构**: MIT | **已开源** | **ICLR 2026**

**设计动机**：异步训练（多个 actor 产生数据，一个 learner 消费数据）在工业界是标配，但 off-policy 数据的 IS ratio 分布不稳定。VCPO 的核心洞察是：**与其事后裁剪极端 IS ratio，不如在更新时就根据"有效样本量"动态调整学习步长**。

**核心方法**：- **ESS (Effective Sample Size) 动态学习率**：用 IS 权重计算当前 batch 的有效样本量，有效样本少时（off-policy 程度高）自动降低学习率 - **OPOB (Optimal Baseline)**：闭式最小方差基线，理论上最优的 baseline 选择

**面临的挑战**：- ESS 估计本身依赖 IS 权重的准确性，在极端 off-policy 场景下可能不可靠 - 动态学习率可能导致训练速度波动，需要平衡稳定性和效率

### 3.5 其他方案概览

| 算法 | arXiv | 核心思路 | 关键贡献 |
|---|---|---|---|
| **ProRL** | 2505.24864 | 周期性重置 reference policy，防止 IS ratio 偏离过远 | 证明延长 RL 可突破 base model 推理边界 |
| **GMPO** | 2507.20673 | Token reward 的**几何平均**替代算术平均，对 outlier 不敏感 | 微软，已开源 |
| **OTB** | 2602.07078 | Token 级最优基线，用 forward-pass 概率近似梯度范数 | 计算效率与稳定性兼顾 |
| **Dr. MAS** | 2602.08847 | Agent-wise 归一化，解决多智能体梯度干扰 | 多 Agent 训练理论证明 |

---

## 四、探索效率：突破 On-Policy 局限

### 4.1 问题分析

LLM Agent 的探索面临独特困难：

- **On-policy 局限**（3 篇）：模型只能从当前能力范围内采样，无法发现全新的策略模式
- **困难样本欠采样**（3 篇）：简单问题成功率高，主导训练数据；困难问题采不到正例
- **计算成本**（5 篇）：Agent 任务的 rollout 涉及环境交互（API 调用、代码执行），比纯文本生成慢数倍
- **冷启动**（2 篇）：模型完全不会做的任务无法获得任何正奖励，RL 无法启动

### 4.2 EMPO2 —记忆增强探索

**Paper**: Exploratory Memory-Augmented Optimization (arXiv: 2602.23008) | **机构**: Microsoft | **ICLR 2026**

**设计动机**：标准 on-policy RL 的根本问题是**探索经验无法跨 episode 传递**——Agent 在第 100 次尝试中犯了一个错误，第 101 次尝试时完全不记得这件事。人类之所以能高效探索，是因为我们有**记忆**：记住哪些方向行不通、哪些策略有效。EMPO2 的核心问题是：**能否给 LLM Agent 一个类似的"探索记忆"?**

**核心方法**：Hybrid on/off-policy 训练 + 自生成记忆系统：

1. **失败轨迹总结**：Agent 对失败的交互轨迹生成总结性 tips（"在这个场景下不应该先搜索，应该先分析已有信息"）
2. **三种训练模式**：
   - On-policy without tips: 标准探索
   - On-policy with tips: 带记忆提示的探索（参数学习 + 非参数记忆的联合）
   - Off-policy with deleted tips: 将 tips 中的知识内化到参数中（去掉 tips 后仍能做到）
3. **内在奖励**：鼓励发现新状态，避免重复已知的失败路径

这是一种 **parametric（参数学习）+ non-parametric（外部记忆）**的双重更新机制。

**关键成果**：ScienceWorld +128.6%, WebShop +11.3%, OOD 场景平均 +136%。

**面临的挑战**：- Tips 生成质量取决于模型的自我反思能力，弱模型可能生成误导性的 tips - 记忆库的管理（增删、去重、优先级）在大规模场景下是工程问题 - Off-policy 训练阶段的 tips 删除策略（何时删、删哪些）缺乏理论指导 - +128.6% 的提升在特定 benchmark 上，泛化到其他 Agent 任务的效果待验证

### 4.3 LUFFY —混合策略学习

**Paper**: Learning under Off-Policy Guidance (arXiv: 2504.14945) | **机构**：字节跳动/港大

**设计动机**：标准 GRPO 的 on-policy 采样意味着模型永远只能从"自己当前会的"里学。如果一个推理模式模型从未在预训练中见过，on-policy 采样几乎不可能碰到它。LUFFY 的问题是：**能否用外部专家的 demonstrations 作为探索信号，引导模型学习超出自身能力的策略？**

**核心方法**：Mixed-Policy GRPO，将 off-policy demonstrations 混入 on-policy rollouts。关键创新是加入 IS 正则化项，防止模型过度拟合 off-policy 数据而丢失 on-policy 学到的能力。

**关键成果**：OOD 场景 +6.2 分，证明模型确实学到了超出当前能力的推理模式。

**面临的挑战**：- 依赖**高质量 off-policy demonstrations** 的可获得性 - IS 正则化的强度需要精细调优，过强则 off-policy 信号被压制，过弱则过拟合 - 混合训练的 on/off-policy 比例是经验性的

### 4.4 其他方案概览

| 算法 | arXiv | 核心思路 | 效率提升 |
|---|---|---|---|
| **TreePo** | 2508.17445 | 前缀共享 + 早停剪枝的树结构 rollout | GPU 时间节省 22%-43% |
| **LADDER** | 2503.00735 | 模型自己递归生成 progressively easier variants，从简单问题获得正奖励 | 冷启动 1%→82% |
| **SGE** | 2603.02045 | 策略空间探索（用自然语言表达高级策略） | Google DeepMind |
| **SSRL** | 2508.10874 | 完全 offline，增强内部知识利用，不依赖外部搜索引擎 | 成本降至零 |

---

## 五、信用分配：长程归因的精细化

### 5.1 问题分析

信用分配是 Agentic RL **最具技术挑战**的问题。考虑一个四轮交互：

1. Agent 搜索了一条无关信息
2. 基于错误信息做了一个决策
3. 发现决策有误，重新搜索
4. 基于正确信息给出正确答案 → **最终成功**

Outcome Reward 只知道"成功了"，但无法区分：第 1 轮（无效搜索，应惩罚）、第 2 轮（错误决策，应惩罚）、第 3 轮（纠正能力，应奖励）、第 4 轮（正确输出，应奖励）的贡献。如果对所有轮次给相同的正 advantage，模型会同时强化有效和无效的行为。

**初学者补充**：信用分配问题在 RL 中由来已久 (temporal credit assignment problem)，但在 LLM Agent 场景中特别严重，因为 (1) 轨迹极长（数百 token / 数十轮交互），(2) 每轮行为之间有复杂依赖关系，(3) 没有像 Atari 游戏那样的中间分数信号。

### 5.2 GiGPO —锚点状态分组

**Paper**: Anchor State Grouping (暂无独立 arXiv，概念来源于多篇工作) | 被 ProxMO 等后续工作引用

**设计动机**: GRPO 的 group-level advantage 是在**同一问题的不同完整轨迹之间**做比较。但在多步任务中，这太粗了——两条轨迹可能在前 3 步完全一样，只在第 4 步分叉。GiGPO 的问题是：**能否利用这些"自然分叉点"做更细粒度的比较?**

**核心方法**: **Anchor State Grouping** —在同一任务的多条 rollout 轨迹中，识别自然重复出现的**相同环境状态** (anchor states)。将这些状态作为"锚点"，聚合来自不同轨迹但在**同一状态下采取不同动作**的经验，构建 step-level 的动作比较组。

直觉上：如果两条轨迹都到达了同一个中间状态 $s$，但一条选了动作 $a_1$ 后成功、另一条选了 $a_2$ 后失败，那么 $a_1$ 在状态 $s$ 下应该获得正 advantage、$a_2$ 获得负 advantage。

**关键创新**: 不需要额外 rollout——利用已有采样中的自然重叠实现细粒度信用分配。

**面临的挑战**: - 需要不同轨迹之间有**足够的状态重叠**，在高度分支的任务中重叠可能很少 - "相同状态"的判定在连续文本空间中需要近似匹配，精确匹配几乎不可能 - 在轨迹空间很大时，锚点数量有限，信用分配的精度受限

### 5.3 ELPO —错误定位与分层归因

**Paper**: Error-Localized Policy Optimization (arXiv: 2602.09598) | **机构**: 阿里巴巴 | **ICLR 2026**

**设计动机**: 推理链中的错误往往有一个**不可挽回的转折点**——在这一步之前，推理方向是对的；从这一步开始，后续所有推理都建立在错误基础上。如果能精确定位这个"首个不可挽回的错误步骤" (first irrecoverable step)，就能有针对性地训练模型避免这类错误。

**核心方法**: 1. **二分搜索定位**: 在一条失败轨迹的推理链上，通过 rollout tree 和二分搜索定位 first irrecoverable step 2. **分层优势归因**: 错误步骤之前的内容获得接近零的 advantage（方向正确但不完整）；错误步骤获得强负 advantage；错误步骤之后放宽 IS clipping 允许更强的纠正性更新

**关键创新**: 首次提出"first irrecoverable step"概念，将信用分配从统计平均转向精确定位。

**面临的挑战**: - 二分搜索需要在每个候选分割点做 rollout，**计算开销显著** - "不可挽回"的定义可能是任务特定的——在某些任务中，即使早期出错也可以在后续纠正 - 对于并非"一步错、步步错"的任务（如多轮搜索，各轮相对独立），这个假设不成立

### 5.4 ProxMO —语义邻近性软聚合

**Paper**: Proximity-Based Multi-Turn Optimization (arXiv: 2602.19225) | **机构**: 腾讯/港理工 | **ICLR 2026**

**设计动机**: GiGPO 的 anchor state grouping 使用**离散匹配**——状态要么完全匹配（分在同一组），要么不匹配（不分组）。但在文本空间中，两个状态可能语义非常接近但字面不同。ProxMO 的问题是：**能否用连续的语义相似度替代离散匹配?**

**核心方法**: - **Step-level**: 沿用 anchor state 思路，但通过**连续语义加权**（而非离散分组）导出 baseline。语义距离越近的状态对 baseline 贡献越大 - **Episode-level**: 感知问题难度，对不同难度的问题调整梯度强度（难题的成功/失败更有信息量）

**关键创新**: Plug-and-play，不需要修改模型架构或训练框架，可以直接叠加在 GRPO/DAPO 上。

**面临的挑战**: - 语义相似度的计算质量取决于 embedding 模型，嵌入质量直接影响 baseline 的准确性 - 加权方案中的温度参数需要调优 - 计算语义相似度带来的额外开销（虽然比 ELPO 的二分搜索小）

### 5.5 其他方案概览

| 算法 | arXiv | 核心思路 | 归因粒度 |
|---|---|---|---|
| **Step-GRPO** | 2503.12937 | 为每个推理步骤独立设计 Reasoning Accuracy Reward 和 Validity Reward | Step-level |
| **ARPO** | 2507.19849 | 熵自适应 rollout + 步骤级奖励，多轮工具交互中每个 action 获得精确反馈 | Step-level |
| **VinePPO** | 2410.01679 | 完全移除 Value network，用完整 trajectory return 的 MC 估计替代 | Token-level (无偏) |

| 算法 | arXiv | 核心思路 | 归因粒度 |
|---|---|---|---|
| **IGPO** | 2510.14967 | 信息增益 = 模型对正确答案信心的边际变化（同时解决奖励稀疏） | Turn-level |

---

## 六、Agentic 工程实践

算法之外，工业界的 Agentic RL 训练还面临大量**工程层面的挑战**。以下是两个公开了详细技术报告的系统：

### 6.1 GLM-5 —异步 Agent RL 基础设施

**Paper**: arXiv: 2602.15763 | **机构**: 智谱 AI | **已开源** | **LMArena #1**

GLM-5 是目前公开信息最详尽的 Agentic RL 工程实践报告。其五阶段 pipeline 中，Agentic RL 是关键阶段。核心工程贡献：

- **异步 RL 基础设施**: Agent 任务的 rollout 涉及环境交互（API 调用、数据库查询），延迟不可预测。GLM-5 设计了异步 actor-critic 架构，actor 独立与环境交互，learner 消费已完成的轨迹
- **TITO Gateway**: 管理 Agent 与外部工具的交互，标准化 I/O 格式
- **CUDA 非确定性问题**: GLM-5 团队发现 MoE 路由的 CUDA 非确定性实现会导致训练不稳定——同一输入在不同 GPU 上路由到不同专家，产生不同梯度。他们强制使用确定性 CUDA 实现来解决

**关键教训**: 算法层面的改进（DAPO、VAPO 等）在工业规模部署时，工程细节（异步调度、CUDA 确定性、环境稳定性）往往比算法本身更决定成败。

### 6.2 Kimi K2 —大规模工具使用训练

**Paper**: arXiv: 2507.20534 (K2), 2501.12599 (K1.5) | **机构**: 月之暗面

Kimi K2 的 Agentic Post-Training 覆盖 3000+ MCP 工具，核心特点：

- **Agentic 数据合成**: 自动化生成 Agent-环境交互数据，覆盖多种工具组合
- **Self-Critique 奖励**: Agent 自己评估自己的输出质量，形成奖励信号（类似 RLAIF 的 Agent 版本）
- **多阶段 RL**: 先 Reasoning RL（RLVR），再 Agentic RL，最后 General RL（RLHF）——逐步扩大 RL 的覆盖范围

**关键教训**: 工具生态的复杂性（3000+ 工具的兼容性、调用格式、错误处理）是一个被论文低估的工程问题。

### 6.3 环境构建

Agentic RL 的瓶颈之一是**训练环境**的可获得性。以下是三个有影响力的环境构建方案：

| 项目 | arXiv | 机构 | 核心思路 |
|---|---|---|---|
| **ABE** | 2508.08791 | 字节/复旦 | 自动化构建 Agent 训练环境，可扩展性强（已开源） |
| **Agent World Model** | 2602.10090 | Snowflake | 代码驱动合成 1000+ 环境，从文本描述自动生成环境（已开源） |
| **ASTRA** | 2601.21558 | 链家 | 基于 MCP 自动合成 Agent 交互轨迹，生成可验证的训练数据（已开源） |
| **GEM** | 2601.10355 | 美团/人大 | 文本到轨迹合成，BFCL +16.5% |

---

## 七、算法速查与对比

### 7.1 全部算法一览

| 算法 | arXiv | 解决的核心挑战 | 核心创新 | 是否需要外部 RM | 开源 |
|---|---|---|---|---|---|
| **SeeUPO** | 2602.06554 | 稳定性 + 信用分配 | Multi-agent 建模 + backward induction | 否 | — |
| **EMPO2** | 2602.23008 | 探索效率 | 自生成记忆 + hybrid on/off-policy | 否 | — |
| **ARLArena** | 2602.21534 | 稳定性 | 4 维分解 + SAMPO 配置 | — | — |
| **IGPO** | 2510.14967 | 奖励信号 + 信用分配 | 信息增益内在奖励 | 否 | — |
| **GiGPO** | — | 信用分配 | Anchor state grouping | 否 | — |
| **ELPO** | 2602.09598 | 信用分配 | 二分搜索定位 first irrecoverable step | 否 | 即将 |
| **ProxMO** | 2602.19225 | 信用分配 | 语义邻近性软聚合 | 否 | — |
| **VCPO** | 2602.17616 | 稳定性 | ESS 动态学习率 + OPOB 基线 | — | |
| **LUFFY** | 2504.14945 | 探索效率 | Mixed-policy GRPO | 否 | — |
| **CM2** | 2602.12268 | 奖励信号 | 7 维度 Checklist 奖励 | 自建 | |
| **GMPO** | 2507.20673 | 稳定性 | Token reward 几何平均 | — | |
| **ProRL** | 2505.24864 | 探索效率 + 稳定性 | 周期性重置 reference policy | — | — |

### 7.2 按影响力分级

基于学术创新（30%）、开源贡献（25%）、工业应用（20%）、机构背书（15%）、后续影响（10%）的综合评估：

| 级别 | 算法/系统 | 理由 |
|---|---|---|
| **Tier 1: 工业标杆** | GLM-5, Kimi K2 | 实际产品部署，商业验证 |
| **Tier 2: 理论突破** | SeeUPO, EMPO2 | ICLR 2026，首创概念 |
| **Tier 3: 方法创新** | VCPO, ELPO, ProxMO, ARLArena | 系统性方法论，已/即将开源 |
| **Tier 4: 专项优化** | IGPO, GiGPO, LUFFY, CM2, GMPO | 特定问题的有效解决方案 |

### 7.3 技术路线图

```
GRPO (2025.01, DeepSeek)
    消除 Critic，定义 RLVR 范式

    DAPO/VAPO (2025.03-04, 字节)
     工业级优化，单轮推理成熟

    奖励信号改进
        IGPO (2025.10, 阿里) → 内在奖励
        CM2 (2026.02, 字节) → 多维度奖励

    训练稳定性
        VCPO (2026.02, MIT) → 方差控制
        ARLArena (2026.02, UCLA) → 系统分析
```

SeeUPO（2026.02，阿里）→ 收敛保证

探索效率

LUFFY（2025.04，字节）→ Off-policy

EMPO$^2$（2026.02，Microsoft）→ 记忆增强

信用分配

GiGPO → 锚点状态

ELPO（2026.02，阿里）→ 错误定位

ProxMO（2026.02，腾讯）→ 语义邻近性

---

下一篇：综合分析与展望 / 返回：目录