Agentic RL 算法与关键技术

> ***研究范围**: 基于 47 篇 Agentic RL 论文（2024-2026 Q1）的系统性分析*
> ***侧重点**: 有影响力的算法的**设计动机**与**面临的挑战***
> ***关联**: 基础算法（GRPO/DAPO/VAPO/CISPO/GSPO/SAPO）的详细推导参见 [Post-Training 报告第一章]*

目录

- 一、从推理 RL 到 Agentic RL：问题的本质变化
- 二、奖励信号：从稀疏到自包含
- 三、训练稳定性：从经验到收敛保证
- 四、探索效率：突破 On-Policy 局限
- 五、信用分配：长程归因的精细化
- 六、Agentic 工程实践
- 七、算法速查与对比

一、从推理 RL 到 Agentic RL：问题的本质变化

1.1 RLVR 的成功与边界

2025 年，RLVR（基于可验证奖励的强化学习）在推理任务上取得了突破性成功。GRPO（arXiv: 2501.12948）消除了 Critic 网络，DAPO（arXiv: 2503.14476）解决了工程稳定性，VAPO（arXiv: 2504.05118）修复了 Value 估计——这些算法在数学、代码等**单轮可验证任务**上已经高度成熟。

但 RLVR 的成功建立在两个隐含假设上：

1. **奖励可验证**: 答案有确定的对/错判定（数学答案、代码测试用例）
2. **单轮决策**: 模型生成一个完整回复，获得一次奖励反馈

当任务变为**多轮交互**（搜索→分析→决策→执行）、**工具使用**（调用 API、操作环境）、**长程规划**（数十步才有最终结果）时，这两个假设同时失效。这就是 Agentic RL 面临的根本挑战。

1.2 Agentic RL 的核心矛盾

> *Agent 任务的**长程性**、**开放性**、**交互性** vs RL 算法对**短程**、**可验证**、**单步决策**的假设*

Agent 任务特征	RL 算法假设	产生的挑战
长程推理（数百步）	短程决策（10-100 步）	信用分配困难、方差爆炸
开放式目标	可验证奖励	奖励稀疏、难以设计
多轮环境交互	单步反馈	延迟反馈、归因不清
巨大动作空间（语言+工具）	小动作空间	探索低效

1.3 四大核心挑战

基于 47 篇论文的统计分析，Agentic RL 面临四大核心挑战：

挑战	论文提及频率	本质
奖励信号质量	68%	如何在长程交互中获得高质量学习信号
训练稳定性	53%	如何控制长序列带来的梯度方差爆炸
探索效率	44%	如何在巨大的语言动作空间中高效探索
信用分配	44%	如何将最终奖励归因到每个决策步骤

这四个挑战并非独立——奖励信号是**源头**（稀疏/噪声导致方差爆炸），信用分配是**桥梁**（精确归因能改善奖励质量），训练稳定性是**保障**，探索效率是**最终目标**：

```
奖励信号质量 （源头）
      ↓ 稀疏/噪声 → 方差爆炸
训练稳定性 ←→ 信用分配 （桥梁）
      ↓ 不稳定 → 限制探索
探索效率 （最终目标）
```

二、奖励信号：从稀疏到自包含

2.1 问题分析

Agentic 任务中，奖励信号面临三重困境：

- **稀疏奖励**（16/47 篇提及）：Agent 经过数十步交互后才获得成/败信号，中间步骤无反馈
- **噪声奖励**（4 篇）：使用外部 Reward Model 评估开放式任务时，RM 本身不够准确
- **Advantage Collapse**（3 篇）：GRPO 的组内归一化在全组获得相同 reward 时，advantage 退化为零，梯度消失

📖 **初学者补充**: 推理 RL（如 DeepSeek-R1）的奖励是「答案是否正确」——这是一个**二值信号**，清晰且可靠。但 Agent 任务（如「帮我调研某个话题并写一份报告」）的「正确」标准模糊得多，如何给这类任务打分是一个开放问题。

2.2 IGPO — 信息增益作为内在奖励

> ***Paper**: Information Gain-based Policy Optimization (arXiv: 2510.14967) | **机构**: 阿里巴巴*

设计动机: 多轮搜索/交互任务中，最终答案的对/错无法区分每一轮交互的贡献。一次有效的搜索操作和一次无效的搜索操作在 Outcome Reward 下看起来完全一样。IGPO 的核心问题是：**能否用模型自身的"信心变化"作为奖励信号，完全不依赖外部 RM?**

核心方法: 在每一轮交互 t，计算模型产生正确答案的概率。Turn-level 奖励定义为**该概率相对于上一轮的边际增加量**：

- 如果本轮搜索让模型对正确答案更有信心 → 正奖励
- 如果本轮搜索没有帮助或造成干扰 → 负奖励

这本质上是一种**内在奖励**（intrinsic reward），完全从模型自身的 belief update 中推导，不需要任何外部标注或奖励模型。

关键创新: 同时解决了两个问题——(1) 奖励稀疏：每轮都有信号；(2) Advantage Collapse：不同轮次的信息增益天然不同。

面临的挑战:

- 仍需要**最终答案可验证**（需要知道正确答案来计算概率），对完全开放式任务不适用
- 计算每轮条件概率需要额外的 forward pass，增加训练开销
- 模型的"信心"不总是与真实准确性一致（校准问题）

2.3 CM2 — 多维度 Checklist 奖励

> ***Paper**: Checklist Rewards for Multi-turn Tool-use (arXiv: 2602.12268) | **机构**: 字节跳动 | **已开源***

设计动机: 单一标量奖励无法区分 Agent 行为的多个维度。一个 Agent 可能正确选择了工具但参数传错了，也可能工具选错了但格式完美——标量奖励无法捕捉这种差异。

核心方法: 设计 7 个细粒度评估组件，为每轮交互提供多维度密集反馈。Checklist 涵盖工具选择准确性、参数正确性、输出格式、任务进展等维度，每个维度独立评分。

面临的挑战:

- Checklist 的设计高度**任务特定**，换一个任务域就需要重新设计评估维度
- 维度之间的权重平衡缺乏理论指导
- 评估维度越多，标注/自动评估的成本越高

2.4 其他方案概览

算法	arXiv	核心思路	适用场景
EDGE-GRPO	2507.21848	引入熵项打破组内相同 reward 导致的 advantage=0	Advantage Collapse
ReGFT	2603.01223	提供部分人工参考解法作为 hint，引导模型生成它原本无法独立生成的正确轨迹	困难问题冷启动（本质是 SFT 而非 RL）
PF-PPO	2409.06957	基于 RM 不确定性过滤不可靠样本，只用高置信度奖励训练	噪声 RM 场景
ZeroSearch	2505.04588	用 LLM 模拟搜索引擎，避免真实 API 的噪声文档	搜索增强任务
DARS	2508.13755	多阶段 rollout 采样，为低准确度困难问题动态分配更多 rollouts	困难样本欠采样

三、训练稳定性：从经验到收敛保证

3.1 问题分析

Agentic 任务的长序列和多轮交互引发严重的训练不稳定：

- **IS ratio 极端化**（6 篇）：长序列中，token-level importance sampling 权重容易溢出，导致更新失控

- **Outlier tokens**（4 篇）: 个别 token 的极端奖励主导整个更新方向
- **Value 估计偏差**（3 篇）: Value network 在长 CoT 中不准确，导致 advantage 错误
- **多轮 RL 不收敛**: 传统算法（PPO、GRPO）在多轮任务上**缺乏收敛保证**

📖 **初学者补充**: Importance Sampling (IS) ratio 是 $\pi_\theta(a|s)/\pi_{\text{old}}(a|s)$，衡量新旧策略的差异。在长序列中，每个 token 的 IS ratio 相乘后可能变得极大或极小，这就是为什么长序列 RL 比短序列难得多。

3.2 SeeUPO — 首个多轮 RL 收敛保证

> ***Paper**: Sequence-Level Sequential Update with Convergence Guarantee (arXiv: 2602.06554) | **机构**: 阿里巴巴 | **ICLR 2026***

设计动机: SeeUPO 的出发点是一个**理论层面的发现**——它证明了传统算法（PPO、GRPO）在 multi-turn 任务上存在一个根本性的矛盾：**无 Critic（GRAE）和训练收敛不可得兼**。

具体来说：

- Value-Free 算法（GRPO 类）无法区分多轮中各轮的贡献 → 梯度有偏 → 不收敛
- 即使用 Critic（PPO 类），在多轮中 Value 估计误差累积也会导致偏差

这意味着**直接把单轮 RL 算法搬到多轮场景，理论上就不对**。

核心方法: SeeUPO 将 multi-turn 交互重新建模为**多个 Agent 的顺序决策问题**——第 1 轮的行为由 Agent 1 决定，第 2 轮由 Agent 2 决定... 然后通过 **backward induction**（反向逐轮更新策略），从最后一轮倒推回第一轮，保证**单调改进**和**全局最优收敛**。

直觉上，这类似于博弈论中的逆向归纳：先想清楚最后一步应该怎么做，再基于此推导倒数第二步... 直到第一步。

关键成果: AppWorld +43.3%, BFCL +24.1%。这是**首个理论上证明 multi-turn RL 可收敛到全局最优**的算法。

面临的挑战:

- Backward induction 需要**逐轮更新**，训练开销随轮次线性增长
- "多 Agent 建模"假设各轮相对独立，但实际上各轮之间有复杂依赖
- 收敛保证依赖于采样质量，实际中有限采样可能偏离理论条件
- 目前仅在对话式任务上验证，对超长步骤的 Agent 任务（如软件工程）的适用性未知

3.3 ARLArena/SAMPO — 系统性稳定性分析框架

> ***Paper**: Unified Framework for Stable Agentic RL (arXiv: 2602.21534) | **机构**: UCLA*

设计动机: Agentic RL 训练频繁崩溃，但社区对不稳定性的来源缺乏系统性理解。不同论文各自修补一个问题（IS clipping、advantage 归一化、loss 聚合...），但没有人从全局视角分析：**哪些因素真正导致崩溃，哪些改进是关键的，哪些是无关紧要的?**

核心方法: ARLArena 将 Policy Gradient 算法分解为四个正交维度进行系统测试：

1. **IS Clipping**: 如何限制 importance sampling 权重（token-level vs sequence-level，裁剪范围）
2. **Dynamic Filtering**: 如何过滤极端样本（基于 reward、advantage、trajectory 质量）
3. **Advantage Assignment**: 如何计算优势函数（token-level vs step-level vs trajectory-level）

4. **Loss Aggregation**: 如何聚合多个 token/step 的 loss

通过控制变量实验，ARLArena 发现了训练崩溃的根本原因：**负优势 + 宽松 IS 裁剪轨迹的累积**。具体来说，当一条轨迹获得负 advantage 但 IS ratio 因裁剪范围过宽没被有效限制时，这条轨迹会产生过大的负梯度，多条这样的轨迹累积就导致崩溃。

基于分析，ARLArena 提出 **SAMPO**（Stable Agentic Policy Optimization）配置，在四个维度上选择最稳定的组合。

面临的挑战:

- 框架是**描述性**的（告诉你什么组合稳定），不是**规范性**的（无法预测新场景的最优配置）
- 最优配置可能随模型规模、任务类型变化
- 四个维度的交互效应复杂，全组合搜索成本高

3.4 VCPO — 方差控制的动态学习率

> ***Paper**: Variance-Controlled Off-Policy RL (arXiv: 2602.17616) | **机构**: MIT | **已开源** | **ICLR 2026***

设计动机: 异步训练（多个 actor 产生数据，一个 learner 消费数据）在工业界是标配，但 off-policy 数据的 IS ratio 分布不稳定。VCPO 的核心洞察是：**与其事后裁剪极端 IS ratio，不如在更新时就根据"有效样本量"动态调整学习步长**。

核心方法:

- **ESS（Effective Sample Size）动态学习率**: 用 IS 权重计算当前 batch 的有效样本量，有效样本少时（off-policy 程度高）自动降低学习率
- **OPOB（Optimal Baseline）**: 闭式最小方差基线，理论上最优的 baseline 选择

面临的挑战:

- ESS 估计本身依赖 IS 权重的准确性，在极端 off-policy 场景下可能不可靠
- 动态学习率可能导致训练速度波动，需要平衡稳定性和效率

3.5 其他方案概览

算法	arXiv	核心思路	关键贡献
ProRL	2505.24864	周期性重置 reference policy，防止 IS ratio 偏离过远	证明延长 RL 可突破 base model 推理边界
GMPO	2507.20673	Token reward 的**几何平均**替代算术平均，对 outlier 不敏感	微软，已开源
OTB	2602.07078	Token 级最优基线，用 forward-pass 概率近似梯度范数	计算效率与稳定性兼顾
Dr. MAS	2602.08847	Agent-wise 归一化，解决多智能体梯度干扰	多 Agent 训练理论证明

四、探索效率：突破 On-Policy 局限

4.1 问题分析

LLM Agent 的探索面临独特困难：

- **On-policy 局限**（3 篇）: 模型只能从当前能力范围内采样，无法发现全新的策略模式
- **困难样本欠采样**（3 篇）: 简单问题成功率高，主导训练数据；困难问题采不到正例
- **计算成本**（5 篇）: Agent 任务的 rollout 涉及环境交互（API 调用、代码执行），比纯文本生成慢数倍
- **冷启动**（2 篇）: 模型完全不会做的任务无法获得任何正奖励，RL 无法启动

4.2 EMPO2 — 记忆增强探索

> ***Paper**: Exploratory Memory-Augmented Optimization (arXiv: 2602.23008) | **机构**: Microsoft | **ICLR 2026***

设计动机: 标准 on-policy RL 的根本问题是**探索经验无法跨 episode 传递**——Agent 在第 100 次尝试中犯了一个错误，第 101 次尝试时完全不记得这件事。人类之所以能高效探索，是因为我们有**记忆**：记住哪些方向行不通、哪些策略有效。EMPO2 的核心问题是：**能否给 LLM Agent 一个类似的"探索记忆"?**

核心方法: Hybrid on/off-policy 训练 + 自生成记忆系统：

1. **失败轨迹总结**: Agent 对失败的交互轨迹生成总结性 tips（"在这个场景下不应该先搜索，应该先分析已有信息"）
2. **三种训练模式**:
   - On-policy without tips: 标准探索
   - On-policy with tips: 带记忆提示的探索（参数学习 + 非参数记忆的联合）
   - Off-policy with deleted tips: 将 tips 中的知识内化到参数中（去掉 tips 后仍能做到）
3. **内在奖励**: 鼓励发现新状态，避免重复已知的失败路径

这是一种 **parametric（参数学习）+ non-parametric（外部记忆）** 的双重更新机制。

关键成果: ScienceWorld +128.6%, WebShop +11.3%, OOD 场景平均 +136%。

面临的挑战:

- Tips 生成质量取决于模型的自我反思能力，弱模型可能生成误导性的 tips
- 记忆库的管理（增删、去重、优先级）在大规模场景下是工程问题
- Off-policy 训练阶段的 tips 删除策略（何时删、删哪些）缺乏理论指导
- +128.6% 的提升在特定 benchmark 上，泛化到其他 Agent 任务的效果待验证

4.3 LUFFY — 混合策略学习

> ***Paper**: Learning under Off-Policy Guidance (arXiv: 2504.14945) | **机构**: 字节跳动/港大*

设计动机: 标准 GRPO 的 on-policy 采样意味着模型永远只能从"自己当前会的"里学。如果一个推理模式模型从未在预训练中见过，on-policy 采样几乎不可能碰到它。LUFFY 的问题是：**能否用外部专家的 demonstrations 作为探索信号，引导模型学习超出自身能力的策略?**

核心方法: Mixed-Policy GRPO，将 off-policy demonstrations 混入 on-policy rollouts。关键创新是加入 IS 正则化项，防止模型过度拟合 off-policy 数据而丢失 on-policy 学到的能力。

关键成果: OOD 场景 +6.2 分，证明模型确实学到了超出当前能力的推理模式。

面临的挑战:

- 依赖**高质量 off-policy demonstrations** 的可获得性
- IS 正则化的强度需要精细调优，过强则 off-policy 信号被压制，过弱则过拟合
- 混合训练的 on/off-policy 比例是经验性的

4.4 其他方案概览

算法	arXiv	核心思路	效率提升
TreePo	2508.17445	前缀共享 + 早停剪枝的树结构 rollout	GPU 时间节省 22%-43%
LADDER	2503.00735	模型自己递归生成 progressively easier variants，从简单问题获得正奖励	冷启动 1%→82%
SGE	2603.02045	策略空间探索（用自然语言表达高级策略）	Google DeepMind
SSRL	2508.10874	完全 offline，增强内部知识利用，不依赖外部搜索引擎	成本降至零

五、信用分配：长程归因的精细化

5.1 问题分析

信用分配是 Agentic RL **最具技术挑战**的问题。考虑一个四轮交互：

1. Agent 搜索了一条无关信息
2. 基于错误信息做了一个决策
3. 发现决策有误，重新搜索
4. 基于正确信息给出正确答案 → **最终成功**

Outcome Reward 只知道"成功了"，但无法区分：第 1 轮（无效搜索，应惩罚）、第 2 轮（错误决策，应惩罚）、第 3 轮（纠正能力，应奖励）、第 4 轮（正确输出，应奖励）的贡献。如果对所有轮次给相同的正 advantage，模型会同时强化有效和无效的行为。

📖 **初学者补充**: 信用分配问题在 RL 中由来已久（temporal credit assignment problem），但在 LLM Agent 场景中特别严重，因为 (1) 轨迹极长（数百 token / 数十轮交互），(2) 每轮行为之间有复杂依赖关系，(3) 没有像 Atari 游戏那样的中间分数信号。

5.2 GiGPO — 锚点状态分组

> ***Paper**: Anchor State Grouping (暂无独立 arXiv，概念来源于多篇工作) | 被 ProxMO 等后续工作引用*

设计动机: GRPO 的 group-level advantage 是在**同一问题的不同完整轨迹之间**做比较。但在多步任务中，这太粗了——两条轨迹可能在前 3 步完全一样，只在第 4 步分叉。GiGPO 的问题是：**能否利用这些"自然分叉点"做更细粒度的比较?**

核心方法: **Anchor State Grouping** — 在同一任务的多条 rollout 轨迹中，识别自然重复出现的**相同环境状态**（anchor states）。将这些状态作为"锚点"，聚合来自不同轨迹但在**同一状态下采取不同动作**的经验，构建 step-level 的动作比较组。

直觉上：如果两条轨迹都到达了同一个中间状态 s，但一条选了动作 a_1 后成功、另一条选了 a_2 后失败，那么 a_1 在状态 s 下应该获得正 advantage、a_2 获得负 advantage。

关键创新: 不需要额外 rollout——利用已有采样中的自然重叠实现细粒度信用分配。

面临的挑战:

- 需要不同轨迹之间有**足够的状态重叠**，在高度分支的任务中重叠可能很少
- "相同状态"的判定在连续文本空间中需要近似匹配，精确匹配几乎不可能
- 在轨迹空间很大时，锚点数量有限，信用分配的精度受限

5.3 ELPO — 错误定位与分层归因

> ***Paper**: Error-Localized Policy Optimization (arXiv: 2602.09598) | **机构**: 阿里巴巴 | **ICLR 2026***

设计动机: 推理链中的错误往往有一个**不可挽回的转折点**——在这一步之前，推理方向是对的；从这一步开始，后续所有推理都建立在错误基础上。如果能精确定位这个"首个不可挽回的错误步骤"（first irrecoverable step），就能有针对性地训练模型避免这类错误。

核心方法:

1. **二分搜索定位**: 在一条失败轨迹的推理链上，通过 rollout tree 和二分搜索定位 first irrecoverable step
2. **分层优势归因**: 错误步骤之前的内容获得接近零的 advantage（方向正确但不完整）；错误步骤获得强负 advantage；错误步骤之后放宽 IS clipping 允许更强的纠正性更新

关键创新: 首次提出"first irrecoverable step"概念，将信用分配从统计平均转向精确定位。

面临的挑战:

- 二分搜索需要在每个候选分割点做 rollout，**计算开销显著**
- "不可挽回"的定义可能是任务特定的——在某些任务中，即使早期出错也可以在后续纠正
- 对于并非"一步错、步步错"的任务（如多轮搜索，各轮相对独立），这个假设不成立

5.4 ProxMO — 语义邻近性软聚合

> ***Paper**: Proximity-Based Multi-Turn Optimization (arXiv: 2602.19225) | **机构**: 腾讯/港理工 | **ICLR 2026***

设计动机: GiGPO 的 anchor state grouping 使用**离散匹配**——状态要么完全匹配（分在同一组），要么不匹配（不分组）。但在文本空间中，两个状态可能语义非常接近但字面不同。ProxMO 的问题是：**能否用连续的语义相似度替代离散匹配?**

核心方法:

- **Step-level**: 沿用 anchor state 思路，但通过**连续语义加权**（而非离散分组）导出 baseline。语义距离越近的状态对 baseline 贡献越大
- **Episode-level**: 感知问题难度，对不同难度的问题调整梯度强度（难题的成功/失败更有信息量）

关键创新: Plug-and-play，不需要修改模型架构或训练框架，可以直接叠加在 GRPO/DAPO 上。

面临的挑战:

- 语义相似度的计算质量取决于 embedding 模型，嵌入质量直接影响 baseline 的准确性
- 加权方案中的温度参数需要调优
- 计算语义相似度带来的额外开销（虽然比 ELPO 的二分搜索小）

5.5 其他方案概览

算法	arXiv	核心思路	归因粒度
Step-GRPO	2503.12937	为每个推理步骤独立设计 Reasoning Accuracy Reward 和 Validity Reward	Step-level
ARPO	2507.19849	熵自适应 rollout + 步骤级奖励，多轮工具交互中每个 action 获得精确反馈	Step-level
VinePPO	2410.01679	完全移除 Value network，用完整 trajectory return 的 MC 估计替代	Token-level (无偏)
IGPO	2510.14967	信息增益 = 模型对正确答案信心的边际变化（同时解决奖励稀疏）	Turn-level

六、Agentic 工程实践

算法之外，工业界的 Agentic RL 训练还面临大量**工程层面的挑战**。以下是两个公开了详细技术报告的系统：

6.1 GLM-5 — 异步 Agent RL 基础设施

> ***Paper**: arXiv: 2602.15763 | **机构**: 智谱 AI | **已开源** | **LMArena #1***

GLM-5 是目前公开信息最详尽的 Agentic RL 工程实践报告。其五阶段 pipeline 中，Agentic RL 是关键阶段。核心工程贡献：

- **异步 RL 基础设施**: Agent 任务的 rollout 涉及环境交互（API 调用、数据库查询），延迟不可预测。GLM-5 设计了异步 actor-critic 架构，actor 独立与环境交互，learner 消费已完成的轨迹
- **TITO Gateway**: 管理 Agent 与外部工具的交互，标准化 I/O 格式
- **CUDA 非确定性问题**: GLM-5 团队发现 MoE 路由的 CUDA 非确定性实现会导致训练不稳定——同一输入在不同 GPU 上路由到不同专家，产生不同梯度。他们强制使用确定性 CUDA 实现来解决

关键教训: 算法层面的改进（DAPO、VAPO 等）在工业规模部署时，工程细节（异步调度、CUDA 确定性、环境稳定性）往往比算法本身更决定成败。

6.2 Kimi K2 — 大规模工具使用训练

> ***Paper**: arXiv: 2507.20534 (K2), 2501.12599 (K1.5) | **机构**: 月之暗面*

Kimi K2 的 Agentic Post-Training 覆盖 3000+ MCP 工具，核心特点：

- **Agentic 数据合成**: 自动化生成 Agent-环境交互数据，覆盖多种工具组合
- **Self-Critique 奖励**: Agent 自己评估自己的输出质量，形成奖励信号（类似 RLAIF 的 Agent 版本）
- **多阶段 RL**: 先 Reasoning RL（RLVR），再 Agentic RL，最后 General RL（RLHF）——逐步扩大 RL 的覆盖范围

关键教训: 工具生态的复杂性（3000+ 工具的兼容性、调用格式、错误处理）是一个被论文低估的工程问题。

6.3 环境构建

Agentic RL 的瓶颈之一是**训练环境**的可获得性。以下是三个有影响力的环境构建方案：

项目	arXiv	机构	核心思路
ABE	2508.08791	字节/复旦	自动化构建 Agent 训练环境，可扩展性强（已开源）
Agent World Model	2602.10090	Snowflake	代码驱动合成 1000+ 环境，从文本描述自动生成环境（已开源）
ASTRA	2601.21558	链家	基于 MCP 自动合成 Agent 交互轨迹，生成可验证的训练数据（已开源）
GEM	2601.10355	美团/人大	文本到轨迹合成，BFCL +16.5%

七、算法速查与对比

7.1 全部算法一览

算法	arXiv	解决的核心挑战	核心创新	是否需要外部 RM	开源
SeeUPO	2602.06554	稳定性 + 信用分配	Multi-agent 建模 + backward induction	否	—
EMPO2	2602.23008	探索效率	自生成记忆 + hybrid on/off-policy	否	—
ARLArena	2602.21534	稳定性	4 维分解 + SAMPO 配置	—	—
IGPO	2510.14967	奖励信号 + 信用分配	信息增益内在奖励	否	—
GiGPO	—	信用分配	Anchor state grouping	否	—
ELPO	2602.09598	信用分配	二分搜索定位 first irrecoverable step	否	即将
ProxMO	2602.19225	信用分配	语义邻近性软聚合	否	—
VCPO	2602.17616	稳定性	ESS 动态学习率 + OPOB 基线	—	✅
LUFFY	2504.14945	探索效率	Mixed-policy GRPO	否	—
CM2	2602.12268	奖励信号	7 维度 Checklist 奖励	自建	✅
GMPO	2507.20673	稳定性	Token reward 几何平均	—	✅

ProRL	2505.24864	探索效率 + 稳定性	周期性重置 reference policy	—	—

7.2 按影响力分级

基于学术创新（30%）、开源贡献（25%）、工业应用（20%）、机构背书（15%）、后续影响（10%）的综合评估：

级别	算法/系统	理由
Tier 1: 工业标杆	GLM-5, Kimi K2	实际产品部署，商业验证
Tier 2: 理论突破	SeeUPO, EMPO2	ICLR 2026，首创概念
Tier 3: 方法创新	VCPO, ELPO, ProxMO, ARLArena	系统性方法论，已/即将开源
Tier 4: 专项优化	IGPO, GiGPO, LUFFY, CM2, GMPO	特定问题的有效解决方案

7.3 技术路线图

```
GRPO (2025.01, DeepSeek)
 │  消除 Critic，定义 RLVR 范式
 │
 ├── DAPO/VAPO (2025.03-04, 字节)
 │   工业级优化，单轮推理成熟
 │
 ├── 奖励信号改进
 │   ├── IGPO (2025.10, 阿里) → 内在奖励
 │   └── CM2 (2026.02, 字节) → 多维度奖励
 │
 ├── 训练稳定性
 │   ├── VCPO (2026.02, MIT) → 方差控制
 │   ├── ARLArena (2026.02, UCLA) → 系统分析
 │   └── SeeUPO (2026.02, 阿里) → 收敛保证 ★
 │
 ├── 探索效率
 │   ├── LUFFY (2025.04, 字节) → Off-policy
 │   └── EMPO² (2026.02, Microsoft) → 记忆增强 ★
 │
 └── 信用分配
     ├── GiGPO → 锚点状态
     ├── ELPO (2026.02, 阿里) → 错误定位
     └── ProxMO (2026.02, 腾讯) → 语义邻近性
```

下一篇: [综合分析与展望](#) | 返回: [目录](#)