Agentic RL 综合分析与展望

> ***说明**: 本篇是基于前一篇算法梳理的宏观分析与个人思考。标注为「💭 个人观点」的部分代表作者主观看法，仅供参考。*

目录

- 一、领域全景：2024-2026 发展脉络
- 二、技术路线分析：哪些方向最有前景
- 三、产业观察：从论文到产品
- 四、核心判断与个人观点
- 五、未来方向与预测

一、领域全景：2024-2026 发展脉络

1.1 时间线

```
2024.08-10  早期探索
  ABE (字节, 环境构建), PF-PPO, VinePPO
  └ 零散工作，尚未形成研究方向

2025.01     拐点：DeepSeek-R1 发布
  GRPO 定义 RLVR 范式
  └ 证明"纯 RL 可涌现推理"，引爆研究热潮

2025.03-05  GRPO 变体爆发期
  DAPO, VAPO, LUFFY, ProRL, Step-GRPO ...
  └ 10+ 变体在 6 个月内涌现，主要优化单轮推理

2025.06-08  过程监督兴起
  ARPO, EDGE-GRPO, TreePo, DARS
  └ 从 outcome-only 走向 step-wise rewards

2025.10-11  方向分化
  IGPO (内在奖励), SAPO (统一框架), IGPO
  └ 算法创新开始分化：有人做统一理论，有人做细分场景

2026.01-03  Agentic RL 论文井喷 ★
  SeeUPO, EMPO², ARLArena, ELPO, ProxMO,
  VCPO, CM2, GLM-5, Dr.MAS, SGE ...
  └ 单月 10+ 篇高质量论文，multi-turn 成为焦点
```

1.2 论文分布

时间段	论文数	热点

2024.08-10	3	早期探索
2025.01	2	GRPO 拐点
2025.02-05	12	GRPO 变体爆发
2025.06-08	8	过程监督 + 效率优化
2025.09-11	4	方向分化
2026.01-03	18	**Agentic RL 井喷**

2026 年 Q1 的论文数量超过前一年全年的 1/3，且集中在 multi-turn、信用分配、训练稳定性——这些恰好是从"推理 RL"扩展到"Agentic RL"时遇到的新问题。

1.3 机构分布

地区	核心机构	论文数	特点
🇨🇳 中国	阿里、字节、DeepSeek、智谱、腾讯、百度、快手	28+ (60%)	论文数量和工业应用均领先
🇺🇸 美国	MIT, UCLA, Microsoft, Google DeepMind, Amazon	10+	方法论创新 + 理论证明
其他	NExT++ (新加坡), CMU	3	专项贡献

中国机构在论文数量和工业落地两个维度上都占据主导。阿里（IGPO, SeeUPO, ELPO, OTB, DARS）和字节（DAPO, CM2, ABE, LUFFY）是论文产出最多的两家。

二、技术路线分析：哪些方向最有前景

2.1 四大挑战的解决进展

挑战	当前进展	成熟度	瓶颈
奖励信号	可验证任务已基本解决；开放式任务仍依赖 RM	★★★☆☆	开放式任务的奖励设计
训练稳定性	SeeUPO 给出收敛保证；ARLArena 提供系统分析	★★★☆☆	理论与工程的差距
探索效率	EMPO2 的记忆机制是突破口；LUFFY 的 off-policy 有效	★★☆☆☆	计算成本仍然很高
信用分配	GiGPO/ELPO/ProxMO 提供了不同粒度的方案	★★☆☆☆	精确归因的计算开销

2.2 三条技术路线

基于现有论文，Agentic RL 的技术路线正在沿三条主线发展：

路线 A: 修复基础算法（Bottom-Up）

从 GRPO/PPO 出发，逐步修复在 Agentic 场景下暴露的缺陷。代表工作：DAPO → VAPO → CISPO → GSPO → SAPO（单轮优化），ARLArena/SAMPO（Agentic 适配）。

- 优势: 渐进式改进，工程风险低
- 劣势: 可能触及单轮算法框架的天花板

路线 B: 重新建模问题（Top-Down）

不再把 Agentic 任务硬塞进单轮 RL 框架，而是从问题本身出发设计新的优化目标。代表工作：SeeUPO（多 Agent 顺序决策建模），IGPO（信息增益奖励）。

- 优势: 理论上更干净，能突破旧框架的局限
- 劣势: 新框架的工程实现和调优经验不足

路线 C: 增强学习基础设施（Infrastructure）

不改算法本身，而是改善数据、环境和记忆系统。代表工作：EMPO2（记忆增强），ABE/Agent World Model（环境合成），ASTRA（轨迹合成）。

- 优势: 与任何算法正交，可叠加
- 劣势: 基础设施的质量直接决定上限

💭 **个人观点**: 短期内路线 A 仍是主流（工业界偏好渐进改进），但路线 B 可能产生下一个"R1 时刻"级别的突破。路线 C 是容易被忽视但极其重要的基础——没有好的环境和数据，再好的算法也无法发挥。

三、产业观察：从论文到产品

3.1 已落地的 Agentic RL 产品

产品	公司	技术基础	状态
GLM-5	智谱 AI	异步 Agent RL + 五阶段 pipeline	商用，LMArena #1 开源
通义千问	阿里云	Agentic RL (DeepResearch)	商用
Kimi K2	月之暗面	Agentic Post-Training + 3000 MCP 工具	开源 + API
Claude Code	Anthropic	Agent RL (细节未公开)	商用
GitHub Copilot	Microsoft	Code Agent RL	商用
Cursor	Anysphere	Code Agent RL	商用

从论文到产品的周期已缩短到 **3-6 个月**。2025 年初的 GRPO 论文，到 2025 年中就有多个产品基于此部署。

3.2 开源生态

类别	开源率	代表项目
GRPO 家族算法	20%	DAPO (verl framework), GMPO
应用/环境	53%	GLM-5, ABE, Agent World Model, ASTRA, CM2
训练框架	—	verl (火山引擎), OpenRLHF

GRPO 家族的算法开源率低（20%），但环境和工具的开源率较高（53%）。这反映了一个现实：算法实现相对简单（论文给了公式），但高质量的训练环境和数据是真正的壁垒。

3.3 中美对比

维度	中国	美国
论文数量	60%+	30%
工业落地	GLM-5, Kimi K2, 通义	Claude Code, Copilot
理论贡献	SeeUPO (阿里)	VCPO (MIT), ARLArena (UCLA)
开源	DAPO, GLM-5, ABE	VCPO, Agent World Model
优势	工程实践、大规模训练、产品迭代快	方法论创新、理论证明

四、核心判断与个人观点

💭 观点 1: 信用分配是 Agentic RL 最本质的难题

四大挑战中，**信用分配**是最难、也最关键的。原因：

- 奖励信号可以通过 IGPO 等内在奖励缓解
- 训练稳定性有 SeeUPO 的理论保证和 ARLArena 的工程指导
- 探索效率可以通过更多计算资源和更好的环境部分解决
- 但信用分配涉及**因果推理**——从相关性（这条轨迹成功了）到因果性（因为第 3 步做对了所以成功），这在哲学层面就是困难的

当前的方案（GiGPO, ELPO, ProxMO）都是**近似**：用状态重叠、二分搜索、语义距离来**猜测**因果关系。真正的突破可能需要引入因果推理（causal reasoning）的工具。

💭 观点 2: SeeUPO 的收敛保证很重要，但实践意义有待验证

SeeUPO 首次证明了 multi-turn RL 可以收敛到全局最优，这在理论上是里程碑式的。但我对其实践影响持谨慎乐观态度：

- 收敛保证依赖于假设（充分采样、各轮相对独立等），实际训练中这些假设很难严格满足
- Backward induction 的计算开销随轮次线性增长，在超长交互（50+ 轮）中可能不实际
- 工业界更关心"在有限计算预算下能达到多好的效果"，而非"无限资源下能否收敛"

但 SeeUPO 的**建模思路**（multi-agent 顺序决策）本身是有价值的，可能启发新的实用算法。

💭 观点 3: 记忆机制（EMPO2）可能是 Agentic RL 的"Attention Is All You Need"

EMPO2 的 +128.6% 提升不仅是数字上的突破，更暗示了一个方向性的转变：**LLM Agent 需要的不仅是更好的策略优化算法，还需要一个持久化的经验系统。**

当前的 RL 训练是 episode-level 的：每个 episode 独立，经验不跨 episode 传递。但人类的学习是累积的——我们记住过去的错误，在新的情境中避免重复。EMPO2 的 tips 生成机制是这个方向的第一步。

如果这个方向被验证，未来的 Agentic RL 训练可能会从"采样 → 优化 → 采样 → 优化"的循环，变成"采样 → 记忆 → 利用记忆探索 → 优化 → 更新记忆"的更丰富的循环。

观点 4: 算法创新的边际收益在递减，工程和数据是真正的壁垒

从 47 篇论文的分析中可以看到：

- 2025 年初的创新（GRPO → DAPO）带来了 **+7 分 AIME** 的巨大提升
- 2025 年中的创新（GSPO → SAPO）提升在收窄
- 2026 年的创新更多集中在**新场景适配**（multi-turn, agentic）而非单轮性能提升

这不是说算法研究不重要——SeeUPO 的收敛保证、ELPO 的错误定位都是关键突破。但对于大多数团队来说，**把现有算法跑好**（高质量数据 + 稳定训练 + 好的环境）可能比追逐最新算法更有价值。

GLM-5 技术报告中一句话令人印象深刻："CUDA 非确定性实现导致的训练不稳定"——这种问题在任何论文里都不会被讨论，但它在工业部署中是致命的。

观点 5: Agentic RL 有可能产生下一个"R1 时刻"

DeepSeek-R1 证明了 RL 可以让推理能力涌现。类似地，Agentic RL 可能让**规划能力**、**工具协调能力**、**自我纠错能力**从 RL 中涌现。EMPO2 的 +128.6% 提升已经显示了端倪。

但 Agentic RL 比 Reasoning RL 难得多：

- 奖励更稀疏（多步交互后才有结果）
- 状态空间更大（包含外部环境状态）
- 评估更困难（没有像数学那样清晰的正确答案）
- 安全性更敏感（Agent 直接与真实环境交互）

如果真的出现"Agentic R1 时刻"，它可能不是来自一个更好的算法，而是来自**环境 + 记忆 + 算法**的组合创新。

观点 6: 环境构建是被严重低估的方向

47 篇论文中，环境构建类的论文（ABE, Agent World Model, ASTRA, GEM）往往不如算法论文受关注，但它们解决的是一个更根本的问题：**训练数据从哪里来?**

Reasoning RL 的训练数据相对容易获取（数学题、代码题有大量现成数据集）。但 Agentic 任务的训练数据需要**环境交互**才能产生，而真实环境交互（API 调用、网页操作）成本高、延迟大、不可逆。

合成环境是解决方案，但合成环境的**逼真度**直接决定了训练的泛化性。目前的合成环境（如 Agent World Model 的 1000 个环境）还远远不够覆盖真实世界的复杂性。

五、未来方向与预测

5.1 短期 (2026)

方向	预期发展	关键指标
算法	SeeUPO/EMPO2 类方法被更多团队验证和改进	多轮 benchmark 上的 SOTA
工程	异步 Agentic RL 训练框架开源（类似 verl 对 GRPO 的作用）	框架 GitHub Stars
产品	更多 Agent 产品上线（代码助手、研究助手、自动化流程）	产品 MAU
评测	Agentic 任务的标准化 benchmark 出现	社区采用度

5.2 中期 (2027)

- **Agentic RL 成为 Post-Training 标配**: 类似 RLHF 在 2023 年成为标配，Agentic RL 阶段将出现在所有主流模型的训练 pipeline 中
- **训练环境生态成熟**: 开源社区提供丰富的 Agent 训练环境，降低入门门槛
- **信用分配的实用方案**: 从当前的启发式方法（锚点、二分搜索、语义距离）走向更有理论支撑的方案

5.3 长期方向

方向	描述	难度
自我进化	Agent 自己生成任务 → 自己探索 → 从成败中学习，形成闭环	★★★★★
世界模型	Agent 学习一个环境模型，在"想象中"做规划和预演	★★★★☆
多 Agent 协作 RL	多个 Agent 通过 RL 学习协作策略	★★★★☆
安全对齐	Agentic RL 的 reward hacking 和安全边界问题	★★★★★
统一框架	将 Reasoning RL 和 Agentic RL 统一到一个优化框架中	★★★☆☆

5.4 总结

Agentic RL 在 2026 年正处于**从学术研究到工业落地的关键转折期**。47 篇论文揭示了四大核心挑战（奖励信号、训练稳定性、探索效率、信用分配），每个挑战都有多条技术路线在探索。

当前最有影响力的突破：

- **SeeUPO**: 首个理论收敛保证——证明 multi-turn RL 是可解的
- **EMPO2**: 记忆增强探索——Agent 可以从历史经验中学习
- **ARLArena**: 系统性分析——告诉我们不稳定性的真正来源
- **GLM-5/Kimi K2**: 工程实践——证明 Agentic RL 可以在产品中工作

这个领域的发展速度极快（6 个月内从概念到产品），但核心问题（特别是信用分配和开放式任务的奖励设计）仍然开放。下一个重大突破可能来自**问题重建模**（像 SeeUPO 那样重新定义优化目标）或**基础设施创新**（像 EMPO2 那样引入新的学习机制），而非对现有算法的增量改进。

上一篇: 算法与关键技术 | 返回: 目录