Agentic RL 调研报告

> ***作者**: Zhen Liang*
> ***最后更新**: 2026-03-17*
> ***定位**: 面向有 RL 基础的读者，系统梳理 Agentic RL（多轮交互、工具使用、长程规划场景下的强化学习）的算法设计、核心挑战与发展方向*
> ***数据来源**: 47 篇论文（2024-2026 Q1）的系统性分析*

报告结构

第一篇：算法与关键技术

从推理 RL 到 Agentic RL 的本质变化，以及有影响力的算法介绍：

- **一、从推理 RL 到 Agentic RL** — 核心矛盾与四大挑战（奖励信号 68%、训练稳定性 53%、探索效率 44%、信用分配 44%）
- **二、奖励信号** — IGPO（信息增益内在奖励）、CM2（多维度 Checklist）及其他方案
- **三、训练稳定性** — SeeUPO（首个多轮收敛保证）、ARLArena/SAMPO（系统分析）、VCPO（方差控制）
- **四、探索效率** — EMPO2（记忆增强探索 +128.6%）、LUFFY（Off-Policy 混合）
- **五、信用分配** — GiGPO（锚点状态）、ELPO（错误定位）、ProxMO（语义邻近性）
- **六、Agentic 工程实践** — GLM-5（异步基础设施）、Kimi K2（3000 工具）、环境构建
- **七、算法速查与对比** — 全部算法一览、影响力分级、技术路线图

第二篇：综合分析与展望

主观评价、分析与未来展望：

- **一、领域全景** — 2024-2026 时间线、论文与机构分布
- **二、技术路线分析** — 三条路线（修复基础算法 / 重新建模 / 增强基础设施）的比较
- **三、产业观察** — 已落地产品、开源生态、中美对比
- **四、核心判断** — 6 条个人观点（💭 标记）：信用分配本质、SeeUPO 实践意义、记忆机制前景...
- **五、未来方向** — 短期/中期/长期预测

与 Post-Training 报告的关系

本报告聚焦 **Agentic RL 的专项算法和挑战**，是对 Post-Training 技术报告 的补充：

内容	Post-Training 报告	本报告
GRPO/DAPO/VAPO 等基础算法	详细公式推导	简要引用
单轮推理 RL	主要焦点	作为背景
多轮/Agentic RL	第三章部分讨论	**核心焦点**
工业技术报告解读	10+ 模型深度解读	GLM-5/Kimi K2 的工程实践
47 篇论文系统分析	未覆盖	**核心内容**

核心论文索引

算法	arXiv	核心贡献	影响力
SeeUPO	2602.06554	首个 multi-turn 收敛保证	Tier 2
EMPO2	2602.23008	记忆增强探索 +128.6%	Tier 2
ARLArena	2602.21534	系统性稳定性分析框架	Tier 3
IGPO	2510.14967	信息增益内在奖励	Tier 4
GiGPO	—	锚点状态分组	Tier 4
ELPO	2602.09598	二分搜索错误定位	Tier 3
ProxMO	2602.19225	语义邻近性软聚合	Tier 3
VCPO	2602.17616	ESS 动态学习率	Tier 3
LUFFY	2504.14945	Off-policy 混合策略	Tier 4
CM2	2602.12268	多维度 Checklist 奖励	Tier 4
GLM-5	2602.15763	异步 Agent RL 基础设施	Tier 1
Kimi K2	2507.20534	大规模工具使用训练	Tier 1

阅读建议

- **快速了解**: 读 README + 第一篇第一节（核心矛盾）+ 第二篇第四节（个人观点）
- **深入算法**: 第一篇第二至五节，每节聚焦一个挑战和对应的关键算法
- **工程视角**: 第一篇第六节（GLM-5/Kimi K2 实践）+ 第二篇第三节（产业观察）
- **研究方向**: 第二篇第二节（技术路线分析）+ 第五节（未来预测）

本报告基于截至 2026 年 3 月的公开论文和技术博客撰写。原始阅读笔记参见 CORE_CHALLENGES_DEEP_REPORT，影响力评估参见 INFLUENCE_ASSESSMENT。