第一章：算法与基本原理

阅读说明：本章系统梳理 LLM Post-Training 的完整技术栈。第一节介绍大模型训练三阶段（Pre / Mid / Post-Training）的全景，第二节将 Post-Training 的两大范式——RLHF 与 RLVR——做一站式概览（含 SFT、RM、DPO 等基础知识），后续各节深入剖析 PPO → GRPO → DAPO → VAPO → CISPO → GSPO → SAPO 的算法演进，包含完整公式推导。涉及难以理解的概念时，会用 **「初学者补充」**模块单独讲解。

目录

- 一、大模型训练全景：Pre-Training / Mid-Training / Post-Training
- 二、Post-Training 两大范式：RLHF 与 RLVR
- 三、DPO —离线偏好优化
- 四、PPO —经典策略优化基础
- 五、GRPO —RLVR 的奠基算法
- 六、DAPO —工业级 RLVR 工程优化
- 七、VAPO —Value-Based 路线的回归与修正
- 八、CISPO —裁剪 IS 权重而非目标函数
- 九、GSPO —序列级策略优化
- 十、SAPO —连续信任域的软门控
- 十一、全部算法公式速查表
- 十二、演进逻辑总结

一、大模型训练全景：Pre-Training / Mid-Training / Post-Training

近年来，大语言模型（LLM）的训练流程逐渐形成了三阶段共识。理解每个阶段的定位是理解 Post-Training 的前提。

参考文献：- *A Survey of Post-training for Large Language Models* (arXiv:2503.06072, 2025) —目前最全面的 Post-Training 综述 - *A Survey on LLM Mid-Training* (arXiv:2510.23081, 2025) —Mid-Training 专项综述 - *The Llama 3 Herd of Models* (arXiv:2407.21783, 2024) —首个系统展示三阶段完整流程的工业级报告

1.1 三阶段全景

```
阶段 1: Pre-Training（预训练）
  目标：语言建模 — 学习语言的统计规律和世界知识
  数据：万亿级 token 的大规模无标注语料
  方法：Next-Token Prediction（自回归语言建模）
  产出：Base Model（基座模型）
  算力：整个训练流程的 ~95%+ 算力消耗在此阶段

阶段 2: Mid-Training（中间训练）[可选]
  目标：能力增强 — 在特定维度上补强基座模型
  数据：十亿至千亿级 token 的高质量定向语料
  方法：继续预训练（Continued Pre-Training），仍以 NTP 为主
  产出：Enhanced Base Model
  典型任务：长上下文扩展、领域适配、多语言增强、代码能力补强

阶段 3: Post-Training（后训练）
  目标：对齐与能力释放 — 让模型"有用、安全、准确"地服务用户
  数据：万至百万级标注数据 + 在线 RL 采样
  方法：SFT, RLHF, DPO, RLVR 等
  产出：Chat / Instruct Model（最终部署模型）
```

1.2 Pre-Training：从数据中学习世界知识

预训练是整个流程的基石。通过在万亿级 token 上做 Next-Token Prediction，模型学习到：

- **语言的统计规律：** 语法、搭配、篇章结构
- **世界知识：** 事实、常识、因果关系
- **推理的"种子"：** 模式匹配、简单逻辑链（后续 RL 将这些种子"释放"为成熟的推理能力）

预训练的核心损失函数：

$$\mathcal{L}_{\mathrm{PT}}(\theta) = -\mathbb{E}_{x\sim\mathcal{D}}\left[\sum_{t=1}^{|x|}\log p_\theta(x_t \mid x_{<t})\right]$$

预训练消耗了整个训练流程 **95% 以上的算力**，是最昂贵的阶段。

1.3 Mid-Training：定向能力增强

Mid-Training（中间训练）是近年逐渐被明确定义的阶段，其目标是**在不破坏预训练知识的前提下，定向增强基座模型的特定能力**。

> **概念澄清：** Mid-Training 有时也被称为 Continued Pre-Training (CPT)、Post Pre-Training 或 Domain Adaptation。arXiv:2510.23081 的综述将其统一定义为"在预训练之后、Post-Training 之前，使用中等规模高质量数据的继续训练阶段"。

Mid-Training 的典型任务：

任务	描述	代表模型
长上下文扩展	将上下文窗口从 8K/32K 扩展到 128K/1M+	LLaMA 3.1 (128K), Qwen2.5-1M (1M)
领域适配	在医学/法律/金融等垂直语料上继续训练	各类行业大模型
多语言增强	补充特定语言的高质量语料	Qwen 系列的多语言增强
代码能力补强	在高质量代码语料上继续训练	DeepSeek-Coder
多模态融合	引入图像/视频/音频理解能力	LLaMA 3.2, Gemma 3

Mid-Training 的核心特征： 1. **仍以语言建模为主要目标**——与 Pre-Training 相同的 NTP 损失 2. **数据规模居中**——比预训练少 1-2 个数量级（十亿～千亿 token），但远多于 Post-Training 3. **不涉及对齐**——不关心"有用、安全、准确"，只关心能力本身

1.4 Post-Training：对齐与能力释放

Post-Training 是将"会说话的机器"变为"有用的助手"的关键步骤。其核心目标是**对齐（Alignment）**——让模型的行为与人类的意图和价值观对齐。

为什么 Post-Training 如此重要？

基座模型（即使经过 Mid-Training）虽然拥有强大的语言能力和知识储备，但存在严重问题：

问题	表现	原因
不遵循指令	给它一个问题，它可能续写更多问题而非回答	预训练目标是"预测下一个 token"，不是"回答问题"
生成有害内容	可能输出歧视性、暴力、虚假信息	训练数据中包含此类内容
推理能力未释放	蕴含推理"种子"但无法系统运用	预训练以记忆为主，未专门优化推理

Post-Training 的里程碑式发现（InstructGPT, arXiv:2203.02155）：**经过 RLHF 后训练的 1.3B 小模型，在人类评估中胜过 175B 的 GPT-3 基座模型**。这证明了后训练的杠杆效应远超参数量扩展。

1.5 三阶段关系与 2025 年趋势

三个阶段并非孤立的，它们之间存在紧密的相互影响：

```
Pre-Training 决定能力"上限"

       Mid-Training 在特定维度上"拉高上限"

              Post-Training "释放"已有能力并"对齐"价值观


  知识储备 → 能力增强 → 对齐与部署
```

2025 年的关键趋势：

1. **Mid-Training 和 Post-Training 的边界逐渐模糊**：例如 DeepSeek-R1 的 Cold Start SFT 既有 SFT 的形式，也有类似 Mid-Training 的功能
2. **Post-Training 的算力占比上升**：随着 RLVR 范式的成功 (DeepSeek-R1, Qwen3)，后训练阶段的 RL 训练算力投入显著增加
3. **"轻量 SFT + 重 RL"**正在成为主流范式 (Meta LLaMA 4, Google Gemini 2.5 均确认了此趋势)

二、Post-Training 两大范式：RLHF 与 RLVR

Post-Training 的核心问题是：**如何告诉模型"什么是好的回答"?** 对这个问题的不同回答，形成了两大范式。

2.1 RLHF 范式：从人类反馈中学习

RLHF (Reinforcement Learning from Human Feedback) 的核心洞察是：**人类虽然很难写出完美的回答，但很擅长比较两个回答的好坏**。

经典三阶段流程

```
阶段 1: SFT (Supervised Fine-Tuning)
   收集 (prompt, demonstration) 数据 → 微调基座模型
   损失: L_SFT = -E[Σ log (y_t | x, y_{<t})]  (只对回答计算损失)
   作用: 学会基本的指令遵循、对话格式

阶段 2: 奖励模型训练 (Reward Model)
   收集 (prompt, response_A, response_B, preference) 数据
   → 用 Bradley-Terry 模型训练 RM 学习人类偏好
   损失: L_RM = -E[log (r(x,y_w) - r(x,y_l))]

阶段 3: RL 优化
   用 PPO 算法，以 RM 分数为奖励，优化策略模型
   目标: max E[r(x,y)] -  ·KL[_ || _ref]
```

RL 优化目标

$$\max_{\pi_\theta} \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta(\cdot|x)} \left[r_\varphi(x,y)\right] - \beta \cdot \mathrm{KL}\left[\pi_\theta(\cdot|x) \,\|\, \pi_{\mathrm{ref}}(\cdot|x)\right]$$

其中 KL 惩罚防止模型为了追求高奖励而偏离正常语言分布太远 (reward hacking)。

奖励模型的已知问题

问题	表现	应对策略
Reward Hacking	模型学会"讨好"RM 而非真正提升质量	KL 惩罚、多 RM 集成 (WARM)
长度偏差	RM 倾向于给更长回答更高分	长度归一化、显式长度惩罚
泛化不足	RM 在训练域外不可靠	迭代式 RM 更新 (LLaMA 3.1 的 6 轮迭代)
分布偏移	策略更新后 RM 面对的输入分布变化	在线 RM 更新、RLVR 绕过 RM

初学者补充：SFT 为什么是必要的第一步？

SFT 教会模型两件事：(1) 输出格式——学会"问题-回答"的对话结构而非无限续写；(2) 基本能力——遵循指令、使用工具、控制输出风格。没有 SFT，直接做 RL 会遇到严重的格式混乱问题（R1-Zero 的教训：语言混杂、输出不可读）。但最新趋势表明 SFT 应该"轻量化"——过重的 SFT 反而会限制 RL 的探索空间。

2.2 RLVR 范式：基于可验证奖励的强化学习

RLVR (RL with Verifiable Rewards) 由 DeepSeek-R1 (arXiv:2501.12948) 开创，其核心思想极其简单：**对于有确定答案的任务，直接用答案正确性作为奖励，完全绕过 RM。**

$$R(\hat{y}, y) = \begin{cases} +1, & \text{is_equivalent}(\hat{y}, y) \\ -1, & \text{otherwise} \end{cases}$$

RLHF vs RLVR 对比

维度	RLHF	RLVR
奖励来源	训练的 RM（近似人类偏好）	规则判定（答案匹配、代码测试通过）
Reward Hacking 风险	高（RM 有漏洞）	**极低**（答案对就是对）
适用任务	通用（对话、创作、对齐）	**仅限有确定答案的任务**（数学、代码、逻辑）
数据需求	需要人类偏好标注	只需（题目，标准答案）对
核心算法	PPO + RM	GRPO, DAPO, VAPO 等
代表模型	InstructGPT, LLaMA 2, Claude	DeepSeek-R1, Qwen3, Seed1.5-Thinking

为什么 RLVR 在推理任务上取得了突破？

1. **零 Reward Hacking**：数学题答案不存在"讨好"的空间，1+1=2 就是 2
2. **信号清晰**：对/错的二元反馈虽然稀疏，但完全没有噪声
3. **可大规模扩展**：数学题可以无限生成，不需要人类标注
4. **涌现能力**：DeepSeek R1-Zero 证明了纯 RLVR 就能让模型涌现出自我反思、纠错等高级推理行为

2025 年的收敛范式 尽管各家的具体实现不同，Post-Training 的 Pipeline 在 2025-2026 年逐渐趋同：

```
通用范式（2025-2026）:
  1. Lightweight SFT — 少量高质量数据，学会格式和基本能力
  2. Reasoning RL（RLVR）— 数学/代码/逻辑，基于规则奖励
  3. [可选] Agentic RL — 工具使用/多轮交互
  4. General RL（RLHF）— 全场景对齐（有用性 + 安全性）
```

三、DPO —离线偏好优化

论文: *Direct Preference Optimization: Your Language Model is Secretly a Reward Model* (Rafailov et al., 2023) **arXiv**: 2305.18290

DPO 是 RLHF 的一个重要简化变体：**绕过 RM，直接从偏好数据优化策略模型。**

3.1 损失函数

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta\log\frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)}\right)\right]$$

DPO 要求模型让好回答 y_w 与坏回答 y_l 之间的对数概率比差距足够大。优点是不需要 RM、训练稳定、易于实现；缺点是依赖离线数据，存在分布偏移问题。

3.2 DPO 的实际定位

DPO 在实际工业应用中的定位越来越清晰：

- **通用对齐**: LLaMA 3.1 大规模对比后发现 DPO 在一般对齐任务上可优于 PPO（但这是有争议的，DeepSeek/ByteDance 经验相反）
- **推理任务**: 在复杂数学/代码推理上，在线 RL（GRPO/DAPO/VAPO）**明显优于** DPO
- **最新趋势**: LLaMA 4 将 DPO 从主力降级为"轻量后处理"步骤，核心推理提升交由 Online RL

  DPO 更多的技术细节和变体（KTO, ORPO, IPO 等）可参考综述 arXiv:2503.06072。

四、PPO —经典策略优化基础

论文: *Proximal Policy Optimization Algorithms* (Schulman et al., 2017) **地位**: 整条演进路线的起点，ChatGPT/InstructGPT 的核心算法

4.1 核心思想

PPO 的目标是：在更新策略时，不要走得太远——通过一个**裁剪的替代目标函数 (clipped surrogate objective)** 平衡探索与稳定。

4.2 核心公式

$$\mathcal{J}_{\text{PPO}}(\theta) = \mathbb{E}_{q\sim P(Q),\, o\sim\pi_{\theta_{\text{old}}}(\cdot|q)}\left[\frac{1}{|o|}\sum_{t=1}^{|o|}\min\left(r_t(\theta)\hat{A}_t,\ \text{clip}(r_t(\theta),\, 1-\varepsilon,\, 1+\varepsilon)\hat{A}_t\right)\right]$$

其中：

- **重要性采样比率**: $r_t(\theta) = \frac{\pi_\theta(o_t|q,o_{<t})}{\pi_{\theta_{\text{old}}}(o_t|q,o_{<t})}$
- **优势函数** $\hat{A}_t$ 由 **GAE (Generalized Advantage Estimation)** 计算：

$$\hat{A}_t^{\text{GAE}(\gamma,\lambda)} = \sum_{l=0}^{T-t-1}(\gamma\lambda)^l\,\delta_{t+l}, \quad \delta_l = R_l + \gamma\,V_\psi(s_{l+1}) - V_\psi(s_l)$$

- V_ψ 是**价值网络 (Critic)**，一个与策略模型同等规模的独立网络
- ε 通常取 0.2

初学者补充：PPO 的三个关键概念

1. **策略 (Policy)**: 在 LLM 中，策略 π_θ 就是模型本身——给定问题 q 和已生成的 token $o_{<t}$，输出下一个 token o_t 的概率分布

2. **重要性采样比率** $r_t(\theta)$：用旧策略采样的数据更新新策略时的偏差矫正系数。$r_t = 1$ 表示新旧一致，$r_t > 1$ 表示新策略更倾向于生成这个 token
3. **优势函数** $\hat{A}_t$："这个动作比平均水平好多少"。$\hat{A}_t > 0$ 表示该动作超出预期（鼓励），< 0 表示低于预期（抑制）

4.3 裁剪机制

`min(r·A, clip(r)·A)` 的效果是**双向限制**：

情况	$\hat{A}_t > 0$（好动作）	$\hat{A}_t < 0$（坏动作）
r_t 太大	裁剪到 $1+\varepsilon$，防止过度增加	不裁剪，允许自由减少
r_t 太小	不裁剪，允许自由增加	裁剪到 $1-\varepsilon$，防止过度减少

4.4 PPO 在 LLM 场景的问题

PPO 最初为游戏/机器人设计，在 LLM 场景中暴露了核心问题：

1. **需要 4 个模型同时在 GPU 上**：策略模型 + 参考模型 + 奖励模型 + 价值网络（Critic），显存开销巨大
2. **Critic 训练困难**：LLM 的奖励通常只在最后一个 token 给出（稀疏奖励），但 Critic 需要在每个 token 位置给出准确的价值估计
3. **长序列中 Critic 不准**：对于长 Chain-of-Thought (CoT) 推理，Critic 估计的误差会累积

这些问题直接催生了 GRPO 的设计。

五、GRPO —RLVR 的奠基算法

> **论文**：*DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models* (Shao et al., 2024) **arXiv**：2402.03300 **地位**：Value-Free RL 路线的开创者，**RLVR 范式的确立**，DeepSeek-R1 的核心算法

5.1 核心思想

GRPO 的核心洞察：**不需要价值网络（Critic），也不需要训练奖励模型**。对同一个问题采样一组（Group）回答，用组内的相对奖励来估计优势，用规则判定（答案是否正确）来提供奖励。

GRPO = Value-Free + RM-Free，这正是 RLVR 范式得以成立的技术基础。

5.2 核心公式

GRPO 目标函数：

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{q\sim P(Q),\,\{o_i\}_{i=1}^{G}\sim\pi_{\theta_{\text{old}}}(\cdot|q)}\left[\frac{1}{G}\sum_{i=1}^{G}\frac{1}{|o_i|}\sum_{t=1}^{|o_i|}\Big(\min\big(r_{i,t}(\theta)\,\hat{A}_{i,t},\ \text{clip}\big(r_{i,t}(\theta),\,1-\varepsilon,\,1+\varepsilon\big)\,\hat{A}_{i,t}\big) - \beta\,\mathbb{D}_{\text{KL}}[\pi_\theta\|\pi_{\text{ref}}]\Big)\right]$$

与 PPO 的关键区别——优势函数的计算方式：

$$\hat{A}_{i,t} = \tilde{r}_i = \frac{R_i - \text{mean}(\mathbf{R})}{\text{std}(\mathbf{R})}$$

其中 $\mathbf{R} = \{R_1, R_2, \ldots, R_G\}$ 是同一问题下 G 个采样回答的奖励集合。在 RLVR 范式下，$R_i \in \{+1, -1\}$（答案对/错）。

初学者补充：Group Relative 是什么意思？

举个例子：对问题"求 $\sqrt{144}$"，模型生成 8 个回答（Group Size $G = 8$）：

回答	正确？	奖励 R_i
o_1："12"		+1
o_2："14"		-1
o_3："12"		+1
o_4："11"		-1
...	...	...

计算：$\text{mean}(\mathbf{R}) = 0,\ \text{std}(\mathbf{R}) = 1$

- 正确回答：$\hat{A} = (1-0)/1 = +1$（鼓励）
- 错误回答：$\hat{A} = (-1-0)/1 = -1$（抑制）

这就是"Group Relative"：优势是**相对于同组其他回答**的，不需要 Critic 网络来估计。

GRPO 的 KL 散度估计器（无偏估计）：

$$\mathbb{D}_{\text{KL}}[\pi_\theta \| \pi_{\text{ref}}] = \frac{\pi_{\text{ref}}(o_{i,t} \mid q, o_{i,<t})}{\pi_\theta(o_{i,t} \mid q, o_{i,<t})} - \log \frac{\pi_{\text{ref}}(o_{i,t} \mid q, o_{i,<t})}{\pi_\theta(o_{i,t} \mid q, o_{i,<t})} - 1$$

5.3 为什么这么设计

设计决策	动机	解决的问题
消除 Critic 网络	Critic 在 LLM 稀疏奖励场景下训练困难	4 模型 $\rightarrow$ 3 模型，节省 ~25% 显存
消除 RM	数学/代码任务有确定答案，不需要学习的奖励模型	杜绝 Reward Hacking
组内相对奖励	对/错的二元奖励天然适合相对比较	无需绝对准确的价值估计
保留 PPO 裁剪	裁剪仍然是稳定训练的有效手段	防止策略突变

5.4 GRPO 的局限

1. **Hard Clipping 丢失梯度**：被裁剪的 token 梯度变为 0，某些稀有但重要的推理词（如"however"，"wait"）可能永远学不到
2. **Token-Level IS 高方差**：逐 token 的重要性采样权重在长序列中波动剧烈
3. **长序列中 Group Baseline 精度不足**：同一组所有 token 共享同一个优势值，无法区分序列内部不同位置的贡献

深入理解：为什么 Hard Clipping 会让被裁剪 token 的梯度变为 0？

PPO/GRPO 的目标函数对单个 token 的贡献：

$$L_t = \min(r_t \hat{A}_t,\ \text{clip}(r_t, 1-\varepsilon, 1+\varepsilon) \cdot \hat{A}_t)$$

当 $\hat{A}_t > 0$（好 token）且 $r_t > 1+\varepsilon$ 时（新策略已经大幅增加了这个 token 的概率），min 取常数项 $(1+\varepsilon) \cdot \hat{A}_t$，这是**关于 θ 的常数**，所以 $\nabla_\theta L_t = 0$。

PPO 的裁剪等价于一个二值掩码：

$$\nabla_\theta L_t = \underbrace{M_t}_{\in\{0,1\}} \cdot \hat{A}_t \cdot \nabla_\theta \log \pi_\theta(o_t \mid \cdots)$$

$$M_t = \begin{cases} 0, & \hat{A}_t > 0 \text{ 且} r_t > 1+\varepsilon \quad \text{（已经够鼓励了，停止）} \\ 0, & \hat{A}_t < 0 \text{ 且} r_t < 1-\varepsilon \quad \text{（已经够抑制了，停止）} \\ 1, & \text{otherwise} \quad \text{（继续更新）} \end{cases}$$

对稀有推理词的影响：像"However"这样的词在基座模型中概率可能只有 $\pi_{\text{old}} = 0.005$。模型概率增长到 0.01 时，$r_t = 2.0$，远超 1.2，梯度归零——尽管绝对概率只有 1%，离"学会"还差很远。

六、DAPO —工业级 RLVR 工程优化

论文：*DAPO: An Open-Source LLM Reinforcement Learning System at Scale* (ByteDance Seed & Tsinghua AIR, 2025) **arXiv**：2503.14476 **地位**：首个完全开源的大规模 RLVR 系统，AIME 2024 达到 50%

6.1 核心公式

$$\mathcal{J}_{\text{DAPO}}(\theta) = \mathbb{E}_{(q,a)\sim\mathcal{D},\,\{o_i\}_{i=1}^{G}\sim\pi_{\theta_{\text{old}}}(\cdot|q)} \left[\frac{1}{\sum_{i=1}^{G}|o_i|} \sum_{i=1}^{G}\sum_{t=1}^{|o_i|} \min\Big(r_{i,t}(\theta)\,\hat{A}_{i,t},\ \text{clip}\big(r_{i,t}(\theta),\,1-\varepsilon_{\text{low}},\,1+\varepsilon_{\text{high}}\big)\,\hat{A}_{i,t}\Big) \right]$$

$$\text{s.t.} \quad 0 < \Big|\{o_i \mid \text{is_equivalent}(a, o_i)\}\Big| < G$$

6.2 四大核心改进

改进 ：Clip-Higher（非对称裁剪）

$$\text{clip}(r_{i,t}(\theta),\ 1-\varepsilon_{\text{low}},\ 1+\varepsilon_{\text{high}})$$

实验设定：$\varepsilon_{\text{low}} = 0.2$，$\varepsilon_{\text{high}} = 0.28$。

放宽上界给低概率的"探索性"token 更多增长空间，同时保持下界防止概率坍塌。

改进 ：Dynamic Sampling（动态采样）

约束条件 $0 < |\{o_i \mid \text{is_equivalent}(a, o_i)\}| < G$ 过滤掉全对/全错的 prompt（它们的优势全为 0，梯度为 0），确保每个 batch 都有有效梯度。

改进 ：Token-Level Policy Gradient Loss（全局 Token 归一化）

GRPO 的 sample-level 归一化：

$$\mathcal{L}_{\text{GRPO}} = \frac{1}{G}\sum_{i=1}^{G}\frac{1}{|o_i|}\sum_{t=1}^{|o_i|} L_{i,t}$$

DAPO 的 token-level 归一化：

$$\mathcal{L}_{\text{DAPO}} = \frac{1}{\sum_{i=1}^{G}|o_i|}\sum_{i=1}^{G}\sum_{t=1}^{|o_i|} L_{i,t}$$

Token-level 让每个 token 权重一致，避免长回答中 token 贡献被稀释。消融实验：Token-Level 50.0 vs Sample-Level 43.0 (AIME 2024)。

改进 ：Overlong Reward Shaping（超长输出奖励塑形）

$$R_{\text{length}}(y) = \begin{cases} 0, & |y| \le L_{\max} - L_{\text{cache}} \\ \frac{(L_{\max} - L_{\text{cache}}) - |y|}{L_{\text{cache}}}, & L_{\max} - L_{\text{cache}} < |y| \le L_{\max} \\ -1, & |y| > L_{\max} \end{cases}$$

软惩罚让模型学到"尽量在限制内完成"，而非"长就是错"。

6.3 移除 KL 散度

DAPO 完全移除了 KL 惩罚项。理由：在长 CoT 推理场景中，模型分布需要大幅偏离初始模型才能涌现复杂推理行为，KL 约束反而是障碍。

七、VAPO —Value-Based 路线的回归与修正

> **论文**: *VAPO: Efficient and Reliable Reinforcement Learning for LLM Reasoning with Verifiable Rewards* (ByteDance Seed, 2025) **arXiv**: 2504.05118 **地位**：跨分支融合算法 (PPO + GRPO + DAPO)，AIME 2024 达到 60.4%

7.1 核心论点

"Value-Free（如 GRPO）在短任务上够用，但在**长 CoT 推理**中，Value-Based 有不可替代的优势——只是需要修好 Critic。"

7.2 核心公式

VAPO 总损失函数:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{PPO}}(\theta) + \mu \cdot \mathcal{L}_{\text{NLL}}(\theta) \quad (\mu = 0.1)$$

PPO 部分采用 Clip-Higher + Token-Level Loss + GAE（非 Group Relative）。

正样本模仿学习损失 (Positive-Example LM Loss):

$$\mathcal{L}_{\text{NLL}}(\theta) = -\frac{1}{\sum_{o_i \in \mathcal{T}} |o_i|} \sum_{o_i \in \mathcal{T}} \sum_{t=1}^{|o_i|} \log \pi_\theta(a_t \mid s_t)$$

其中 $\mathcal{T}$ 是当前 batch 中**回答正确的样本集合**。这是一个"自我模仿学习"——对正确回答直接最大化对数似然。去掉此损失，AIME 从 60 降到 54（−6）。

7.3 三大 Critic 修复技术

技术	做法	移除后 AIME 得分
Value Pretraining	RL 开始前用 MC 回报预训练 Critic ~50 步	11（−49，几乎崩溃）
Decoupled GAE	Critic 用 $\lambda = 1.0$（无偏），Policy 用 $\lambda = 0.95$（低方差）	33（−27）
Length-Adaptive GAE	$\lambda_{\text{policy}} = 1 - \frac{1}{\alpha \cdot l}$，让 TD 误差贡献与序列长度成正比	45（−15）

初学者补充：为什么 Value Pretraining 如此关键?

从奖励模型初始化 Critic 会引入**正向偏置**——RM 被训练在 <EOS> 位置打分，对早期 token 给出较低分数。但 Critic 需要在每个 token 给出准确的期望累积回报。没有预训练，Critic 的初始估计完全不靠谱，导致 GAE 计算出的优势全是噪声，RL 从一开始就走向错误方向。

7.4 技术来源总结

技术	来源	创新/继承
Value Model + GAE	PPO	继承
Group Sampling	GRPO	继承
Clip-Higher, Token-Level Loss, Dynamic Sampling	DAPO	继承
Value Pretraining, Decoupled GAE, Length-Adaptive GAE, Positive-Example LM Loss	**VAPO 原创**	创新

7.5 消融实验汇总

移除的组件	AIME 2024	下降
完整 VAPO	**60.4**	—
移除 Value Pretraining	11	−49
移除 Decoupled GAE	33	−27
移除 Length-Adaptive GAE	45	−15
移除 Clip-Higher	46	−14
移除 Token-Level Loss	53	−7
移除 Positive-Example LM Loss	54	−6
原始 PPO（无任何改进）	5	−55

八、CISPO —裁剪 IS 权重而非目标函数

论文: *MiniMax-M1: Scaling Test-Time Compute Efficiently with Thinking Models* (MiniMax, 2025)
arXiv: 2506.13585 **地位**: 首次提出"裁剪 IS 权重而非裁剪目标"的范式

8.1 核心问题

PPO/GRPO 的 Hard Clipping 对推理关键的"分岔词"（如"However"、"Wait"）特别不友好。这些词初始概率低，$r_{i,t}$ 很快超过裁剪阈值，梯度归零。在 MiniMax 的设置中（每 batch 16 轮 off-policy 更新），这些 token 在**第 1 轮就被裁剪出局**，剩下 15 轮完全没有梯度。

8.2 核心公式

$$\mathcal{J}_{\text{CISPO}}(\theta) = \mathbb{E}\left[\frac{1}{\sum_{i=1}^{G}|o_i|}\sum_{i=1}^{G}\sum_{t=1}^{|o_i|}\text{sg}\big(\hat{r}_{i,t}(\theta)\big)\cdot\hat{A}_{i,t}\cdot\log\pi_\theta(o_{i,t}\mid q, o_{i,<t})\right]$$

其中 $\hat{r}_{i,t}(\theta) = \text{clip}\Big(r_{i,t}(\theta),\ 1-\varepsilon_{\text{low}}^{\text{IS}},\ 1+\varepsilon_{\text{high}}^{\text{IS}}\Big)$，$\text{sg}(\cdot)$ 是 stop-gradient。

8.3 PPO vs CISPO 梯度行为

算法	裁剪对象	被裁剪 token 的梯度
PPO/GRPO	目标函数 $r \cdot A$	$= \mathbf{0}$（完全丢失）
CISPO	IS 权重 r（在 sg 内）	$\mathbf{0}$（权重被限制但梯度保留）

CISPO 永远不会将任何 token 的梯度置零。IS 权重被裁剪后通过 sg() 作为常数标量，但 $\log \pi_\theta(\cdot)$ 始终可微：

$$\nabla_\theta \mathcal{J}_{\text{CISPO}} \propto \sum_{i,t} \underbrace{\text{sg}(\hat{r}_{i,t})}_{\text{裁剪后的标量权重}} \cdot \hat{A}_{i,t} \cdot \underbrace{\nabla_\theta \log \pi_\theta(o_{i,t} \mid \cdots)}_{\text{始终有梯度}}$$

九、GSPO —序列级策略优化

论文: *Group Sequence Policy Optimization* (Alibaba / Qwen Team, 2025) **arXiv**: 2507.18071 **地位**: 将优化粒度从 Token-Level 提升到 Sequence-Level，应用于 Qwen3

9.1 核心问题

GRPO 的 Token-Level IS 存在**理论缺陷**：奖励是 sequence-level 的，但 IS 矫正是 token-level 的——优化单元与奖励单元不匹配。更关键的是，token-level IS 权重对"分岔词"造成剧烈波动，在 MoE 模型中尤其不稳定（专家路由切换导致个别 token 的 $r_{i,t}$ 突变）。

9.2 核心公式

$$\mathcal{J}_{\text{GSPO}}(\theta) = \mathbb{E}\left[\frac{1}{G}\sum_{i=1}^{G} \min\Big(s_i(\theta)\,\hat{A}_i,\ \text{clip}(s_i(\theta),\,1-\varepsilon,\,1+\varepsilon)\,\hat{A}_i\Big)\right]$$

序列级 IS 比率（逐 token 比率的几何平均）：

$$s_i(\theta) = \left(\frac{\pi_\theta(y_i \mid q)}{\pi_{\theta_{\text{old}}}(y_i \mid q)}\right)^{1/|y_i|} = \exp\left(\frac{1}{|y_i|}\sum_{t=1}^{|y_i|} \log \frac{\pi_\theta(y_{i,t} \mid q, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t} \mid q, y_{i,<t})}\right)$$

9.3 GRPO vs GSPO 梯度对比

- **GRPO**: 同一序列内的不同 token 有**不同权重** $w_{i,t}$
- **GSPO**: 同一序列内的所有 token 有**相同权重** s_i

这消除了 token 间的不一致性，也使得 MoE 模型不受个别 token 专家切换的影响（GRPO 需要 Routing Replay 来解决此问题，GSPO 不需要）。

9.4 极小裁剪范围

由于 $s_i(\theta)$ 经过了 $1/|y_i|$ 归一化，数值范围远比 token-level 紧凑：

$$\varepsilon_{\text{left}} = 3 \times 10^{-4}, \quad \varepsilon_{\text{right}} = 4 \times 10^{-4}$$

(对比 GRPO 的 $\varepsilon = 0.2 \sim 0.28$，差了三个数量级)

十、SAPO —连续信任域的软门控

论文: *Soft Adaptive Policy Optimization* (Alibaba / Qwen Team, 2025) **arXiv**: 2511.20347 **地位**: 用连续的 Soft Gating 替代所有先前算法的 Hard Clipping，应用于 Qwen3-VL

10.1 核心问题

所有先前算法都使用某种形式的 Hard Clipping。Hard Clipping 在裁剪边界处存在**不连续的梯度跳变**，难以平衡稳定性与有效学习。

10.2 核心公式

Soft Gating 函数:

$$f_{i,t}(x) = \sigma\big(\tau_{i,t} \cdot (x-1)\big) \cdot \frac{4}{\tau_{i,t}}$$

温度参数根据优势符号自适应：$\tau_{\text{pos}} = 1.0$，$\tau_{\text{neg}} = 1.05$（非对称温度）。

梯度权重：$w_{i,t}(\theta) = 4 \cdot p \cdot (1-p)$，其中 $p = \sigma(\tau(r-1))$。

- 在 $r = 1$（on-policy）处取最大值 $w = 1$
- 随 r 偏离 1 **平滑对称衰减**（sech^2 形状）
- 永远不为零

10.3 统一视角：三种 Gating 函数

算法	$f(r)$ 形式	边界行为
GRPO	$\min(r, 1+\varepsilon)$	超过阈值后**水平截断**，梯度 $= 0$
GSPO	$\min(s_i, 1+\varepsilon)$（序列级）	超过阈值后**水平截断**
SAPO	$\frac{4}{\tau}\sigma(\tau(r-1))$	**平滑 S 形饱和**，从不完全截断

10.4 与 GSPO 的联系

论文证明在温和条件下，SAPO 的 token-level soft gate 会**自动近似坍缩为 sequence-level gate**，不需要显式选择 token-level 还是 sequence-level——它在 token-level 定义，但自然地表现出 sequence-level 的行为。

10.5 为什么要非对称温度

- **正优势** $(\hat{A} > 0)$：更新是**聚焦的**——增加采样 token 的 logit，降低其他 token 的 logit，方差小
- **负优势** $(\hat{A} < 0)$：更新是**发散的**——降低采样 token 的 logit，但提升**所有其他 token**（词表大小 ~100K+）的 logit，梯度被分散到大量无关 token，方差大

$\tau_{\text{neg}} > \tau_{\text{pos}}$ 使得负样本的梯度衰减更快，抑制高方差效应。

十一、全部算法公式速查表

算法	目标函数核心	优势函数	IS 粒度	裁剪/门控	范式
PPO	$\min(r_t A_t, \text{clip}(r_t) A_t)$	GAE + Critic	Token	对称硬裁剪	RLHF
GRPO	$\min(r_{i,t}\hat{A}_i, \text{clip}(r_{i,t})\hat{A}_i)$	Group Relative	Token	对称硬裁剪	**RLVR**
DAPO	$\min(r_{i,t}\hat{A}_i, \text{clip}_{\text{asym}}(r_{i,t})\hat{A}_i)$	Group Relative	Token	**非对称**硬裁剪	**RLVR**
VAPO	同 DAPO $+ \mu \cdot \mathcal{L}_{\text{NLL}}$	GAE + **Adaptive** Critic	Token	非对称硬裁剪	**RLVR**
CISPO	$\text{sg}(\text{clip}(r_{i,t})) \cdot \hat{A}_i \cdot \log \pi$	Group Relative	Token	裁剪 **IS 权重**	**RLVR**
GSPO	$\min(s_i\hat{A}_i, \text{clip}(s_i)\hat{A}_i)$	Group Relative	**Sequence**	硬裁剪（极小 ε）	**RLVR**
SAPO	$\frac{4}{\tau}\sigma(\tau(r-1)) \cdot \hat{A}_i$	Group Relative	Token $\to$ Seq	**Soft Gating**	**RLVR**

十二、演进逻辑总结：每一步解决了什么问题

PPO（RLHF） 稳定的策略优化框架
问题：Critic训练困难、显存占用过高（4模型）、RM有Reward Hacking风险

GRPO（RLVR） 消除Critic+RM，用Group Relative + 规则奖励
问题：Hard Clip丢失梯度 + 熵崩塌 + Token-Level IS高方差

DAPO 非对称裁剪 + 动态采样 + Token归一化
（工程化解决GRPO实际训练中的一系列问题）
问题：裁剪本身的梯度丢失问题仍未根治

CISPO 裁剪IS权重而非目标函数 → 所有token保留梯度
（从根本上解决梯度丢失）

GSPO Token-Level → Sequence-Level
（从根本上解决IS高方差 + MoE不稳定）
问题：硬裁剪在序列级仍有突变

SAPO Soft Gating替代Hard Clip
（连续信任域，非对称温度，自然坍缩到序列级）

VAPO 回归Value-Based，修好Critic
（Value预训练 + 解耦GAE + 长度自适应GAE）
（证明：修好后的Value-Based在长CoT上更强）

其他值得关注的算法：

算法	arXiv	核心贡献
Dr. GRPO	2503.20783	发现 GRPO 存在使错误回答长度增加的优化偏差，提出无偏优化
REINFORCE++	2501.03262	全局优势归一化（跨全局 batch 而非仅组内），指出 GRPO 的局部归一化是有偏估计器
PRIME	2502.01456	通过隐式过程奖励实现在线 PRM 更新，推理 benchmark 平均提升 15.1%

下一章：第二章：技术报告解读与训练经验