第二章：技术报告解读与训练经验

阅读说明：本章对 2025-2026 年主流大模型的 Post-Training 技术报告进行深度解读。每个模型的分析**重证据**——列出完整的报告来源（arXiv 编号或博客链接），**重动机**——分析"为什么这么做"而非仅仅"做了什么"，**重技术**——深入关键设计选择的理论基础和工程权衡。

目录

- 一、DeepSeek-R1 —纯 RL 推理涌现
- 二、DeepSeek-V3 —高效后训练与蒸馏
- 三、Qwen3 —Thinking Mode Fusion
- 四、Kimi K1.5 / K2 —Agentic Post-Training
- 五、Seed1.5-Thinking —DAPO/VAPO 工业验证
- 六、LLaMA 3.1 / 4 —从 DPO 到 Online RL 的转向
- 七、GLM-5 —异步 Agent RL 与工程教训
- 八、Gemini 2.5 —可验证奖励与思考预算
- 九、OpenAI o 系列—RL 驱动的推理 Scaling
- 十、跨模型训练经验总结

一、DeepSeek-R1 —纯 RL 推理涌现

报告：*DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning* **arXiv**: 2501.12948 (2025.01) **核心主张**：纯 RL 可以让推理能力从零涌现，不需要人工标注的推理轨迹

1.1 动机分析

DeepSeek-R1 面对的核心问题是：**如何让模型学会复杂的多步推理（如竞赛级数学），而不需要昂贵的人工推理链标注？**

传统思路（SFT on CoT data）受限于标注员的推理能力和标注成本。DeepSeek 提出了一个大胆假设：基座模型在预训练中已经蕴含了推理的"种子"，RL 的作用是**选择性地激活和强化这些种子**，而非从零教授推理。

1.2 Pipeline：四阶段

```
DeepSeek-V3 Base（671B MoE，37B 激活参数）

    阶段 1: Cold Start SFT
      数据：数千条长 CoT 样本（人工标注或少量蒸馏）
      目的：学会 <think>...</think> 格式，避免 R1-Zero 的格式混乱

    阶段 2: Reasoning RL ← 核心阶段
      算法：GRPO（无 Critic，无 RM）
      奖励：基于规则（数学答案匹配 + 格式检查）
      发现："aha moment" — 模型自发学会反思和纠错

    阶段 3: Rejection Sampling + SFT
      从阶段 2 模型采样 ~800K 高质量回答 → 重新 SFT
      目的：巩固推理能力 + 恢复通用能力

    阶段 4: All-Scenario RL
      多种任务上做最终对齐（有用性 + 安全性）


DeepSeek-R1（AIME 2024: 79.8% pass@1）
```

1.3 R1-Zero：纯 RL 的涌现与局限

DeepSeek 做了一个极端实验——**R1-Zero**：跳过所有 SFT，直接在基座模型上做 GRPO。

涌现行为（报告 Figure 3-4）：

行为	描述	意义
"aha moment"	模型自发学会"Wait, let me reconsider ..."并纠正推理错误	自我反思能力从 RL 中自然涌现，不是被教会的
思维链自然延长	困难问题上自动生成更长的推理过程	模型学会了按需分配"思考预算"
自我验证	学会回头检查计算结果	类似人类的元认知能力

暴露的问题：语言混杂（多种语言混用）、可读性差、格式不稳定。这些问题说明**纯 RL 能涌现推理能力，但需要 SFT 来提供基本的格式和可读性约束。**

1.4 失败尝试（报告 Section 3.4 一极有价值的负面结果）

尝试	结果	报告中的分析
Process Reward Model (PRM)	效果不如 Outcome RM	PRM 难以准确标注中间步骤的正确性，容易被 reward hack
Monte Carlo Tree Search (MCTS)	在 LLM 场景不 work	搜索空间太大、value 估计不准、token-level 搜索不匹配推理粒度
直接基座 RL（R1-Zero）	能力涌现但不可用	需要 SFT 提供格式约束

1.5 GRPO 的选择理由

报告给出的技术论证：- 对 671B MoE 模型，训练同等规模的 Critic 网络**显存不可承受**（节省 ~25%+ 显存）- 数学/代码任务有确定答案，基于规则的奖励 + Group Relative 优势已经足够 - 避免 Critic 在长 CoT 推理中的累积误差

二、DeepSeek-V3 一高效后训练与蒸馏

> **报告**：*DeepSeek-V3 Technical Report* **arXiv**：2412.19437 (2024.12) **核心主张**：通过 R1 蒸馏 + Self-Rewarding，以极低算力完成高质量后训练

2.1 动机分析

DeepSeek-V3 面对的问题是：**如何在已有 R1 推理能力的前提下，高效地将这种能力整合到通用模型中？**从头做 RL 太贵，但直接 SFT on R1 数据又会损失通用性。

2.2 关键数据

指标	数值	意义
SFT 数据量	~1.5M instances	大规模蒸馏 + 合成
Post-Training 总算力	**仅 5K H800 GPU hours**	极高效率
MTP 接受率	85-90%	Multi-Token Prediction 加速推理

2.3 R1 蒸馏 Pipeline

```
阶段 1: 用 R1 生成推理数据
阶段 2: 双轨 SFT
      推理任务: 用 R1 生成的长 CoT 回答
      通用任务: 用标准格式回答
阶段 3: RL 微调 (使用 Self-Rewarding)
阶段 4: Rejection Sampling
```

Self-Rewarding 的核心思想：模型自己给自己的输出打分，用于构建偏好数据，避免训练独立 RM。这是 Constitutional AI 思路在推理模型上的延伸。

2.4 关键技术洞察

报告揭示了一个重要的工程权衡：**蒸馏 vs 从头 RL**

维度	R1 蒸馏	从头 RL
GPU 成本	~5K H800 hours	估计 10× 以上
推理能力	接近 R1 水平	可能超越 R1
通用能力	需要双轨 SFT 保持	各阶段 RL 分别优化
风险	低（SFT 是确定性过程）	高（RL 不稳定）

三、Qwen3 —Thinking Mode Fusion

报告: *Qwen3 Technical Report* **arXiv**: 2505.09388 (2025.05) **核心主张**: 在单一模型中统一 thinking 和 non-thinking 模式，用极少量数据实现大幅推理提升

相关报告: - Qwen2.5 Technical Report: arXiv:2412.15115 - GSPO (Qwen3 的核心 RL 算法): arXiv:2507.18071

3.1 动机分析

Qwen3 面对两个核心挑战：

1. **Thinking 模式的用户体验问题**: 所有问题都用长 CoT 回答（像 DeepSeek-R1）会导致简单问题也输出大段思考过程，用户体验差且推理成本高
2. **数据效率问题**: 能否用最少的数据和 RL 步数，释放基座模型已有的推理潜力?

3.2 Pipeline: 四阶段

```
Qwen3 Base (Dense: 0.6B-32B, MoE: 30B-235B)

      阶段 1: Long-CoT Cold Start SFT
        少量高质量长 CoT 数据，学会 <think>...</think> 格式

      阶段 2: Reasoning RL
        算法: GRPO
        数据: 仅 3,995 个 query-verifier 对！
        结果: AIME 2024 从 70.1 → 85.1 (仅 170 步 RL)

      阶段 3: Thinking Mode Fusion SFT ← 核心创新
        混合 thinking 模式 + non-thinking 模式数据
        让模型学会根据问题难度自动选择是否"思考"
```

```
阶段 4: General RL
  全场景对齐，使用 GSPO 算法


Qwen3 Chat (thinking/non-thinking 自由切换)
```

3.3 关键技术洞察

发现 1：极高的数据效率

仅 **3,995 个 query-verifier 对 + 170 步 RL** 就将 AIME 2024 从 70.1 提升到 85.1（+15 分）。这强力佐证了"RL 释放已有能力"而非"RL 教授新能力"的观点——基座模型已经蕴含了推理能力。

发现 2：Thinking Mode Fusion 的实现

报告描述了 Thinking Mode Fusion SFT 的关键细节：- 混合 thinking 模式数据（复杂问题 + 长 CoT）和 non-thinking 模式数据（简单问题 + 直接回答）- 模型学会通过问题特征判断是否需要启动思考 - 涌现出"Thinking Budget"能力——根据问题难度自适应分配思考长度

发现 3：强到弱蒸馏

用大模型的推理能力蒸馏到小模型，GPU 成本仅为从头 RL 训练的 1/10。这为资源受限的团队提供了实用路径。

3.4 Qwen2.5 的对比参考

arXiv: 2412.15115

Qwen2.5 采用了更传统的四阶段流水线（SFT → Offline DPO → Online GRPO → 长上下文微调）。相比之下，Qwen3 的核心变化是：

维度	Qwen2.5	Qwen3
RL 算法	GRPO	GRPO → GSPO
DPO 阶段	核心阶段（~150K 偏好对）	不再使用
推理模式	无 thinking mode	Thinking Mode Fusion
RM 架构	6 维 RM（有用性/安全性/正确性/格式/完整性/风格）	继承 + 简化

Qwen2.5 的 **6 维 RM** 值得关注——多维 RM 允许在 RL 阶段对不同维度设置不同权重（如安全性高权重、格式低权重），避免了单一分数 RM 的模糊性。

四、Kimi K1.5 / K2 —Agentic Post-Training

K2 报告: *Kimi K2: Open Agentic Intelligence* **K2 arXiv**: 2507.20534 (2025.07)

K1.5 报告: *Kimi k1.5: Scaling Reinforcement Learning with LLMs* **K1.5 arXiv**: 2501.12599 (2025.01)

核心主张：大规模 Agentic 训练数据合成 + 自批评奖励机制

4.1 动机分析

Kimi 团队面对的核心问题与 DeepSeek/Qwen 不同：**如何让模型学会使用工具和在真实环境中完成任务？**纯数学推理的 RLVR 范式无法直接应用于 Agentic 任务，因为"工具调用是否正确"很难用简单规则判定。

4.2 K1.5：推理 Scaling 的简约路线

K1.5 报告（arXiv:2501.12599）的核心发现：

- 使用长上下文扩展 + 改进策略优化实现 SOTA 推理（AIME 77.5, MATH500 96.2）
- **无需 MCTS、价值函数或过程奖励模型**——与 DeepSeek-R1 的结论一致
- 提出 **long2short** 方法：用长 CoT 技术提升短 CoT 模型性能

4.3 K2：Agentic Post-Training

指标	数值
总参数	1.04T (MoE)
激活参数	~32B
RL 算法	GRPO 变体

Agentic 数据合成：K2 最大的创新是大规模 Agentic 训练数据的合成：

- 集成 **3000+ 真实 MCP (Model Context Protocol) 工具**
- 让模型在**真实工具环境**中交互，收集轨迹（而非模板生成）
- 自动化流程不断扩展工具覆盖面

Self-Critique Rubric Rewards：K2 没有训练独立的 RM，而是让模型自己根据预定义的评分维度（rubric）对回答进行批评：

1. 模型生成回答
2. 模型根据 rubric **自我批评**
3. 自我批评结果 → 奖励信号

优势：评分标准通过 rubric 灵活调整，无需重新训练 RM。

MuonClip 优化器：K2 使用自研的 MuonClip 优化器，在 15.5T token 的预训练中实现**零 loss spike**——这对 MoE 模型训练至关重要（MoE 的训练不稳定性是公认难题）。

五、Seed1.5-Thinking —DAPO/VAPO 工业验证

> **报告**：*Seed1.5-Thinking: Advancing Superb Reasoning Models with Reinforcement Learning* **arXiv**：2504.13914 (2025.04) **核心主张**：VAPO 在工业规模上稳定优于 DAPO；RFT 会伤害后续 RL

5.1 动机分析

Seed1.5-Thinking 的独特价值不在于提出新算法，而在于**在工业规模上系统验证了 DAPO 和 VAPO 的相对表现**。这是目前唯一在 200B MoE 模型上对两种 RLVR 路线进行 head-to-head 比较的公开报告。

5.2 模型与结果

指标	数值
总参数	200B (MoE)
激活参数	20B
AIME 2024	86.7
Codeforces	55.0
GPQA	77.3

5.3 核心发现

发现 1：VAPO 稳定优于 DAPO（+10 分）

> 报告 Table 2：在 AIME 等多个 benchmark 上，VAPO 一致性领先 DAPO 约 10 分。

这验证了 VAPO 论文的核心主张："Value-Free 在短任务上够用，但在长 CoT 推理中，修好的 Value-Based 更强"。VAPO 的三大 Critic 修复技术（Value Pretraining, Decoupled GAE, Length-Adaptive GAE）在 200B MoE 上同样有效。

发现 2：RFT 伤害后续 RL（非常反直觉）

> 报告 Section 4.3：先做 Rejection Sampling Fine-tuning 再做 RL，效果**不如直接从 Cold Start SFT 进入 RL**。

传统思路认为"先用 RFT 提升起点 → 再用 RL 进一步优化"应该更好。但数据表明：

Pipeline	AIME 2024
Cold Start SFT → RL	**更高**
Cold Start SFT → RFT → RL	更低

报告给出的分析：1. RFT 让模型输出分布变窄（只保留"正确"模式），降低了 RL 阶段的探索多样性 2. RL 需要模型在"错误"中学习——如果模型已经很少犯错，RL 信号变弱 3. RFT 可能引入"false positive"模式——推理路径有缺陷但答案碰巧正确的回答

实践建议：如果最终目标是做 RL，考虑跳过 RFT 阶段。

发现 3：DAPO 在大规模上依然有效

作为完全开源方案，DAPO 在 200B MoE 上验证了其四大改进（Clip-Higher, Dynamic Sampling, Token-Level Loss, Overlong Reward Shaping）的实际价值。

六、LLaMA 3.1 / 4 —从 DPO 到 Online RL 的转向

> **LLaMA 3.1 报告**：*The Llama 3 Herd of Models* **LLaMA 3.1 arXiv**：2407.21783 (2024.07)
>
> **LLaMA 4 博客**：ai.meta.com/blog/llama-4-multimodal-intelligence/ (2025.04)
>
> **核心叙事**：Meta 从 LLaMA 3.1 到 LLaMA 4 的后训练策略发生了根本性转向

6.1 LLaMA 3.1：DPO 路线的巅峰

LLaMA 3.1 报告（arXiv:2407.21783）是目前最详尽的工业级 Post-Training 技术报告。其核心特点是 **6 轮迭代训练**：

```
每一轮：
  1. 训练/更新 Reward Model
  2. SFT + Rejection Sampling（用 RM 筛选最佳回答）
  3. DPO 对齐
重复 6 轮，每轮的 RM 和数据都在改进
```

核心发现（有争议）：DPO > PPO

LLaMA 3.1 团队在他们的实验设置下得出结论：**DPO 在一般对齐任务上优于 PPO**。但需注意：

因素	LLaMA 3.1（DPO 优）	DeepSeek-R1（RL 优）
任务类型	通用对齐（helpful, safe）	复杂数学推理
回答长度	相对较短	长 CoT（数千 token）
评估方式	人类偏好评估	数学答案正确性

10 条关键训练经验（报告 Section 4）：

1. **Format Token Masking**: DPO 中 mask 格式 token，只优化内容
2. **NLL 正则化** ($\lambda = 0.2$)：防止 DPO 只学会降低坏回答概率而不提升好回答
3. **Rejection Sampling > 直接 SFT**：用 RM 筛选模型自身生成的最佳回答效果更好
4. **安全性需要独立阶段**：有用性和安全性的优化目标存在张力
5. **迭代训练是核心**：6 轮迭代中每一轮都在改进，单轮远不够

6.2 LLaMA 4：转向 Online RL

LLaMA 4 的后训练发生了**根本性转向**，从 DPO 重心转移到 Online RL：

```
LLaMA 3.1: Heavy SFT → 6轮迭代 DPO
LLaMA 4:   Lightweight SFT → Online RL → Lightweight DPO
```

转向的动机（根据公开信息推断）：

1. **DeepSeek-R1 的成功冲击**：纯 RL 涌现推理能力的结果让 Meta 重新评估在线 RL 的价值
2. **过重的 SFT/DPO 限制 RL 探索空间**：LLaMA 4 团队发现过多的离线优化反而限制了模型的探索能力
3. **Llama-as-judge 数据过滤**：使用模型自身判断删除 50%+ "简单"训练数据，保留真正有梯度信号的样本

架构变化：LLaMA 4 采用 MoE 架构（Scout: 17B×16 专家, Maverick: 17B×128 专家），与 DeepSeek-V3 的 MoE 趋势一致。

七、GLM-5 —异步 Agent RL 与工程教训

报告：*GLM-5: from Vibe Coding to Agentic Engineering* **arXiv**: 2602.15763 (2026.02)

前代报告：*ChatGLM: A Family of Large Language Models from GLM-130B to GLM-4 All Tools* **前代 arXiv**: 2406.12793

核心主张：异步 RL 基础设施解耦生成与训练，实现 Agent RL 的高效训练

7.1 动机分析

GLM-5 面对的核心挑战是：**如何在端到端软件工程等长程交互任务上进行 RL 训练？**传统的同步 RL（生成一批 → 计算奖励 → 更新参数 → 生成下一批）在 Agent 场景中效率极低，因为每一步工具调用都需要等待环境响应。

7.2 Pipeline：五阶段

```
GLM-5 Base

    阶段 1: SFT — 通用指令跟随
    阶段 2: Reasoning RL — 数学/代码/逻辑
    阶段 3: Agentic RL — 工具使用/多轮交互 ← 核心创新
    阶段 4: General RL — 全场景对齐
    阶段 5: 跨阶段蒸馏 — 整合各阶段最优能力


GLM-5 Chat (SWE-bench SOTA)
```

7.3 核心技术创新

异步 RL 基础设施

报告提出将 RL 的生成（rollout）和训练（update）**解耦为异步流水线**：

- **生成进程**：持续与环境交互，将完成的轨迹放入缓冲区
- **训练进程**：从缓冲区取轨迹，计算梯度，更新参数
- 两个进程异步运行，避免了同步等待的瓶颈

这对 Agent RL 至关重要——Agent 任务中每步工具调用可能需要数秒到数分钟（如执行代码、调用 API），同步等待会让 GPU 利用率极低。

TITO Gateway (Think-In, Think-Out)

模型可以在输出中嵌入"思考段落"，这些思考段落在最终输出时被过滤掉。类似于 Qwen3 的 Thinking Mode，但实现为一个显式的 gateway 机制。

跨阶段蒸馏（阶段 5）

解决 RL 各阶段之间的**能力遗忘**问题：

- Reasoning RL 提升推理但可能损害对话
- Agentic RL 提升工具使用但可能损害推理
- 跨阶段蒸馏将每个阶段的"最优版本"作为教师，综合蒸馏到最终模型

7.4 关键工程教训

非确定性 CUDA Top-K 的致命问题（报告 Section 5.3）

> "CUDA 的 top-k 操作在某些情况下是非确定性的（nondeterministic），这会导致 RL 训练在几步之内崩溃。"

根因分析：RL 训练中，IS 比率 $r_{i,t} = \pi_\theta / \pi_{\theta_{\text{old}}}$ 需要精确的概率分布。如果 top-k 采样在不同前向传播中给出不同结果（GPU 浮点运算的非确定性），$r_{i,t}$ 出现异常值 $\rightarrow$ 梯度爆炸 $\rightarrow$ 训练崩溃。

解决方案：强制使用确定性的 top-k 实现（牺牲一些性能），或在 RL 训练阶段避免 top-k 采样。

这个发现对所有做 MoE + RL 的团队都有警示意义。

八、Gemini 2.5 —可验证奖励与思考预算

技术报告：Gemini 2.5 Report (PDF) (2025.03) **博客**：Google DeepMind Blog

相关论文： - BOND: *Best-of-N Distillation* - WARM: *Weight Averaged Reward Models* (arXiv:2401.12187) - WARP: *Weight Averaged Rewarded Policies* - Gemma 3 Technical Report: arXiv:2503.19786

核心主张：重度使用可验证奖励 + 基于模型的生成式奖励，实现 LMArena Elo +122 分

8.1 动机分析

Google 的 Post-Training 哲学与其他厂商有显著差异。他们的核心思路不是"找到最好的 RL 超参数"，而是"**训练多个模型，然后在权重空间中平均**"——这是一种更稳健、更可复现的路线。

8.2 Gemini 2.5 的后训练策略

报告透露了几个关键信息：

1. **大幅增加 RL 计算量**：相比前代，Gemini 2.5 在 RL 阶段的算力投入显著增加
2. **重点使用可验证奖励**：与 RLVR 范式一致，在有确定答案的任务上使用规则奖励
3. **基于模型的生成式奖励**：对开放性任务，使用 LLM-as-Judge 生成奖励
4. **可控思考预算**：Gemini 2.5 Flash 支持用户指定思考预算（低/中/高），模型按预算分配推理计算

LMArena Elo 提升：- Gemini 2.5 Pro: +122 分 - Gemini 2.5 Flash: +111 分

8.3 权重平均哲学

Google 的三个代表性方法，构成了一个独特的技术路线：

方法	做法	核心思想
BOND	对 prompt 采样 N 个回答，用 RM 选最佳，做 SFT 蒸馏	类似 VAPO 的 Positive-Example LM Loss
WARM	训练多个 RM，在**权重空间**平均	权重平均的 RM 比单个更鲁棒
WARP	多轮 RL（不同种子），在**权重空间**平均策略模型	多次 RL + 权重平均 > 单次精调

为什么权重平均有效?

不同训练轨迹收敛到损失曲面的不同局部最优，这些局部最优各有优缺点。权重平均在这些局部最优之间找一个"中间点"，这个中间点往往比任何单个最优都好（前提是这些模型在同一个损失盆地中）。

8.4 RM 设计特点

特点	描述	与其他厂商的对比
RM ~10× 策略模型	RM 参数量远大于策略模型	DeepSeek/Qwen 用同等或更小的 RM
权重平均 RM	多个 RM 在权重空间平均	其他厂商多用单一 RM
推理时多 RM 投票	部署时用多个 RM 集成打分	更高的推理成本换取更可靠的奖励

九、OpenAI o 系列—RL 驱动的推理 Scaling

o1 博客: openai.com/index/learning-to-reason-with-llms/ (2024.09) **o3-mini**: openai.com/index/openai-o3-mini/ (2025.01) **o3 & o4-mini**: openai.com/index/introducing-o3-and-o4-mini/ (2025.04)

注意: OpenAI 未发布详细的技术报告，以下分析基于公开博客和第三方分析

9.1 动机与理念

OpenAI o 系列的核心理念是 **"通过 RL 训练模型学会分配推理时间计算 (test-time compute)"**。这与 DeepSeek-R1 的思路一致，但 OpenAI 更早提出了这一方向（o1 发布于 2024 年 9 月）。

9.2 关键里程碑

模型	日期	核心贡献	关键指标
o1	2024.09	首次大规模 RL 训练推理模型	AIME 2024 74%, GPQA Diamond 77.3%
o3-mini	2025.01	高性价比推理，三档推理力度	支持低/中/高推理力度
o3/o4-mini	2025.04	RL 计算量较 o1 提升一个数量级	o4-mini AIME 2025 pass@1 **99.5%**

9.3 关键技术线索

虽然 OpenAI 未公开技术细节，从公开信息可以推断:

1. **纯 RL 路线**: o1 博客明确表示"纯 RL 训练，无需人工推理标注"——与 DeepSeek-R1 的结论一致
2. **Test-Time Compute Scaling**: 模型学会了根据问题难度分配更多推理计算，与 Qwen3 的 Thinking Budget 和 Gemini 2.5 Flash 的可控思考预算异曲同工
3. **o3/o4 的工具使用 RL**: o3 首次通过 RL 训练模型学习**何时调用工具**，这是 Agentic RL 的早期信号
4. **Deliberative Alignment**: o3-mini 采用了一种新的安全方法——模型在推理过程中主动考虑安全约束

9.4 与开源模型的对比

维度	OpenAI o 系列	DeepSeek-R1	Qwen3
技术透明度	低（仅博客）	高（完整论文）	高（完整论文）
RL 算力投入	极高（o3 较 o1 提升 10×）	中等	较低
工具使用 RL	o3 开始支持	无	无
可控推理预算	o3-mini（三档）	无	Thinking Mode（二值切换）

十、跨模型训练经验总结

综合以上 2025-2026 年所有模型的 Post-Training 实践，提炼出以下关键经验：

经验 1：Pipeline 正在收敛

尽管各家实现不同，大框架在 2025 年趋同：

```
Lightweight SFT → Reasoning RL (RLVR) → [Agentic RL] → General RL (RLHF)
```

证据：- DeepSeek-R1 (arXiv:2501.12948): Cold Start SFT → GRPO → Rejection Sampling SFT → All-Scenario RL - Qwen3 (arXiv:2505.09388): Long-CoT SFT → GRPO → Thinking Mode Fusion SFT → GSPO - LLaMA 4 (blog): Lightweight SFT → Online RL → Lightweight DPO - GLM-5 (arXiv:2602.15763): SFT → Reasoning RL → Agentic RL → General RL → Cross-Stage Distillation

经验 2：Online RL 在推理任务上不可替代

方法	通用对齐	复杂推理	证据
DPO	好	一般	LLaMA 3.1 (arXiv:2407.21783)
Online RL (GRPO/DAPO)	好	强	DeepSeek-R1, Qwen3
Online RL + Value (VAPO)	好	**最强**	Seed1.5 (arXiv:2504.13914): VAPO 稳定 +10 分

经验 3：数据质量 > 数据数量 > 模型规模

证据	来源
3,995 个 query + 170 步 RL 提升 15 分	Qwen3 (arXiv:2505.09388)
QwQ-32B 性能匹配 DeepSeek-R1 671B MoE	Qwen 系列
R1 蒸馏仅 5K H800 hours	DeepSeek-V3 (arXiv:2412.19437)

经验 4：RL 的作用是"释放"而非"教授"

多个模型的经验表明，基座模型在预训练中已学到推理的"种子"，RL 的作用是选择性强化。

- R1-Zero 的"aha moment"是涌现的，不是教会的 (arXiv:2501.12948)
- Qwen3 仅 170 步 RL 就提升 15 分 (arXiv:2505.09388)
- SimpleRL-Zoo (arXiv:2503.18892) 在 10 种不同基座模型上复现了涌现行为

经验 5：RFT 不一定是好的 RL 预处理

Seed1.5-Thinking (arXiv:2504.13914) 的发现：RFT 可能限制后续 RL 的探索空间。如果最终目标是做 RL，考虑直接从 Cold Start SFT 进入 RL。

经验 6：MoE 模型的 RL 训练有特殊挑战

挑战	表现	解决方案	来源
专家路由不稳定	token-level IS ratio 剧烈波动	GSPO（序列级）	arXiv:2507.18071
Loss spike	训练中偶发损失尖峰	MuonClip 优化器	Kimi K2 (arXiv:2507.20534)
非确定性计算	CUDA top-k 导致 RL 崩溃	强制确定性实现	GLM-5 (arXiv:2602.15763)

经验 7：蒸馏是高效获取推理能力的捷径

方法	GPU 成本	效果	来源
从头 RL	100%	最强	DeepSeek-R1
强到弱蒸馏	~10%	接近教师水平	Qwen3 (arXiv:2505.09388)
R1 蒸馏 pipeline	~5%	中等水平	DeepSeek-V3 (arXiv:2412.19437)

经验 8：训练阶段之间存在能力遗忘

每个 RL 阶段优化特定能力时会损害其他能力。解决方案：- **混合训练数据**：PPO-ptx 思路 (InstructGPT, arXiv:2203.02155) - **跨阶段蒸馏**：GLM-5 的第五阶段 (arXiv:2602.15763) - **迭代训练**：LLaMA 3.1 的 6 轮迭代 (arXiv:2407.21783)

经验 9：安全性和有用性需要分阶段优化

模型	安全性处理方式	来源
LLaMA 3.1	独立安全性 RL 阶段	arXiv:2407.21783
Qwen2.5	6 维 RM 中安全性独立维度	arXiv:2412.15115
DeepSeek-R1	All-Scenario RL 包含安全性	arXiv:2501.12948
o3-mini	Deliberative Alignment	OpenAI blog

上一章：第一章：算法与基本原理 / 下一章：第三章：发展路线与方向思考