第三章：发展路线与方向思考

> ***阅读说明**: 本章是基于前两章内容的宏观分析与个人思考。包含技术演进时间线、范式变迁分析、核心挑战梳理，以及对未来方向的主观判断。标注为「💭 个人观点」的部分代表作者的主观看法，仅供参考。*

目录

- 一、技术演进时间线
- 二、Post-Training 范式演变
- 三、核心技术挑战
- 四、未来发展方向
- 五、个人观点与判断

一、技术演进时间线

1.1 关键里程碑

```
2017.07  PPO 发布 (Schulman et al.)
         └ 奠定策略优化基础框架

2022.03  InstructGPT 发布 (OpenAI)
         └ 确立 SFT → RM → RLHF 三阶段范式
         └ 证明 1.3B RLHF > 175B Base

2022.12  Constitutional AI (Anthropic)
         └ 提出 RLAIF，用 AI 反馈替代人类反馈

2023.05  DPO 发布 (Stanford)
         └ 绕过 RM，直接从偏好数据优化策略
         └ 大幅简化 pipeline

2024.02  DeepSeekMath → GRPO
         └ 消除 Critic，Group Relative 优势
         └ 开创 Value-Free RL 路线

2024.07  LLaMA 3.1 (Meta)
         └ 6 轮迭代训练，DPO > PPO 的发现
         └ 工业级 Post-Training 最详尽报告

2024.12  DeepSeek-V3 / Qwen2.5
         └ R1 蒸馏 pipeline / 6 维 RM + 四阶段

2025.01  DeepSeek-R1 ★★★
         └ 纯 RL 推理涌现 (R1-Zero "aha moment")
         └ RLVR 范式确立，GRPO 大规模验证
         └ 四阶段 pipeline 成为行业标杆
```

```
2025.03  DAPO (ByteDance Seed)
         └─ 首个完全开源大规模 RL 系统
         └─ 四大工程改进: Clip-Higher, Dynamic Sampling,
            Token-Level Loss, Overlong Reward Shaping

2025.04  VAPO / Seed1.5-Thinking (ByteDance)
         └─ 回归 Value-Based, 修好 Critic
         └─ AIME 60.4%, VAPO 稳定超 DAPO +10 分

2025.05  Qwen3
         └─ Thinking Mode Fusion (thinking/non-thinking 自由切换)
         └─ 3,995 queries + 170 步 RL = +15 分

2025.06  CISPO (MiniMax-M1)
         └─ 裁剪 IS 权重而非目标函数, 保留所有 token 梯度

2025.07  GSPO (Qwen Team) / Kimi K2
         └─ Sequence-Level IS ratio, MoE 友好
         └─ Agentic Post-Training + 3000 MCP 工具

2025.11  SAPO (Qwen Team)
         └─ Soft Gating 替代 Hard Clipping
         └─ 统一 Token/Sequence Level 的理论框架

2026.02  GLM-5 (智谱)
         └─ 五阶段全能 pipeline + 跨阶段蒸馏
         └─ TITO Gateway + 非确定性 CUDA 问题发现

2026.03  Agentic RL 论文井喷
         └─ SeeUPO (首个 multi-turn 收敛保证)
         └─ EMPO² (记忆增强探索 +128.6%)
         └─ ARLArena (系统性稳定性分析框架)
```

1.2 时间线的几个关键转折

转折点	时间	Before → After
InstructGPT	2022.03	"更大更好" → "训练方式更重要"
DPO	2023.05	"必须在线 RL" → "离线也可以"
DeepSeek-R1	2025.01	"RL 辅助 SFT" → "RL 是推理的核心引擎"
DAPO+VAPO	2025.03-04	"GRPO 就够了" → "工程细节决定性能"
GSPO+SAPO	2025.07-11	"Token-Level 优化" → "Sequence-Level 思维"

Agentic RL 论文潮	2026 Q1	"单轮 RL" → "多轮/交互式 RL"

二、Post-Training 范式演变

2.1 四代范式

第一代：SFT-Only (2020-2022)

```
Base Model → SFT → Deploy
```

- **代表**: 早期的 Alpaca, Vicuna
- **核心思路**: 用高质量对话数据直接微调
- **局限**: 模型只会模仿，不会"判断好坏"

第二代：RLHF (2022-2024)

```
Base → SFT → RM Training → PPO/DPO → Deploy
```

- **代表**: InstructGPT, ChatGPT, Claude, LLaMA 2
- **核心思路**: 用人类偏好训练奖励模型，再用 RL 优化
- **突破**: 模型学会了"什么是更好的回答"
- **局限**: RM 容易被 hack，pipeline 复杂，对推理提升有限

第三代：RLVR + Reasoning RL (2025)

```
Base → Cold Start SFT → Reasoning RL (GRPO/DAPO/VAPO) → General RL → Deploy
```

- **代表**: DeepSeek-R1, Qwen3, QwQ
- **核心思路**: 用可验证的规则奖励（答案对错）直接训练推理能力
- **突破**: 推理能力从 RL 中涌现，不再依赖标注数据
- **局限**: 只适用于有确定答案的任务

第四代（正在形成）：Agentic RL (2025-2026)

```
Base → SFT → Reasoning RL → Agentic RL → General RL → Deploy
```

- **代表**: GLM-5, Kimi K2, 以及 2026 Q1 的研究论文
- **核心思路**: 将 RL 扩展到多轮交互、工具使用、环境感知等复杂场景
- **挑战**: 奖励信号更稀疏、信用分配更困难、探索空间更大

2.2 范式演变的驱动力

驱动力	从 → 到	关键论文/事件
人类标注成本	人类偏好 → AI 偏好 → 规则奖励	InstructGPT → CAI → DeepSeek-R1
Reward Hacking	神经网络 RM → 多维 RM → 规则 RM	InstructGPT → Qwen2.5 → DAPO

推理能力需求	通用对齐 → 专项推理 RL	ChatGPT → R1 / QwQ
Agent 能力需求	单轮生成 → 多轮交互	GPT-4 → Kimi K2 / GLM-5
算法效率	PPO (4 模型) → GRPO (3 模型) → DPO (无 RL)	持续追求更简单高效的训练方式

三、核心技术挑战

基于对 50+ 篇论文和 12+ 模型技术报告的分析，当前 Post-Training 领域面临四大核心挑战：

3.1 挑战一：奖励信号质量

问题本质: 如何获得准确、可靠、细粒度的学习信号。

发展脉络:

```
人类标注 (InstructGPT)
    │ 问题: 成本高、不一致、不可扩展
    ▼
神经网络 RM
    │ 问题: Reward Hacking、分布偏移
    ▼
多维 RM (Qwen2.5)        基于规则 RM (DeepSeek-R1)
    │                         │
    │ 问题: 维度间平衡        │ 问题: 只适用于可验证任务
    ▼                         ▼
Self-Critique (Kimi K2)   RLAIF (Claude)
    │                         │
    └──────────┬──────────────┘
               ▼
     Intrinsic Reward (IGPO, 2026)
     信息增益作为自包含奖励信号
```

当前状态:

- 可验证任务（数学/代码）: 基于规则的奖励基本解决了问题
- 通用任务: 仍依赖神经网络 RM，Reward Hacking 未根本解决
- 多轮/Agentic 任务: 奖励信号极度稀疏，是最大瓶颈

3.2 挑战二：训练稳定性

问题本质: 长程推理和交互任务中，梯度方差爆炸、策略震荡。

不稳定性来源	算法层面的应对	工程层面的应对
Token-level IS ratio 极端化	GSPO（序列级）、SAPO（软门控）	Routing Replay (MoE)
Hard Clipping 梯度归零	CISPO（裁剪权重不裁剪梯度）、SAPO	—

Critic 不准确	VAPO（三大修复技术）、VinePPO（移除 Critic）	Value Pretraining
MoE 路由不稳定	GSPO（不依赖单 token 路由）	MuonClip 优化器
CUDA 非确定性	—	强制确定性实现（GLM-5）
多轮 RL 不收敛	SeeUPO（首个收敛保证）	—

💭 **个人观点**: 训练稳定性是一个"冰山问题"——学术论文展示的是冰山一角（算法改进），但真正决定成败的是冰山下面的工程实现。GLM-5 发现的 CUDA 非确定性问题就是典型例子。

3.3 挑战三：探索效率

问题本质: 如何在巨大的语言/动作空间中高效发现有效策略。

问题	表现	代表性解决方案
On-policy 局限	模型只能从自己当前能力范围内学习	LUFFY（混合 off-policy 数据）、ProRL（延长训练突破边界）
困难样本欠采样	简单问题主导训练	DAPO（Dynamic Sampling）、DARS（多阶段 rollout）
冷启动问题	模型完全不会做的任务无法获得正奖励	ReGFT（参考解法引导）、LADDER（自动课程学习）
计算成本	大量 rollout 导致训练缓慢	TreePo（前缀共享 + 早停）、蒸馏（$1/10$ 成本）
记忆缺失	探索经验无法跨 episode 传递	EMPO²（外部记忆 + tips 生成）

3.4 挑战四：信用分配

问题本质: 在长程推理和多轮交互中，如何将最终奖励精确归因到每个决策步骤。

这是 Agentic RL 时代最突出的挑战。在单轮数学推理中，即使用 Sequence-Level 的优势估计（GRPO/GSPO），效果已经不错，因为整个序列只做一件事（解题）。但在多轮交互中：

- 第 1 轮搜索了一个信息
- 第 2 轮基于错误的搜索结果做了决策
- 第 3 轮纠正了错误
- 最终成功

Outcome Reward 只知道"成功了"，但无法区分第 1 轮（无效搜索）、第 2 轮（错误决策）和第 3 轮（关键纠正）的贡献。

代表性解决方案:

方案	粒度	核心思想
GiGPO	Step-level	利用不同轨迹中自然重复出现的相同状态（锚点）构建比较组

IGPO	Turn-level	用模型对正确答案的"信心变化"作为每轮奖励
ELPO	Step-level	二分搜索定位推理链中的首个不可挽回错误
SeeUPO	Turn-level	将多轮交互建模为多智能体顺序决策，反向逐轮更新
ProxMO	Step-level	基于语义邻近性的软聚合 baseline

四、未来发展方向

4.1 方向一：Agentic RL 的成熟

当前状态: Agentic RL 正处于从学术研究到工业落地的关键时期。GLM-5 和 Kimi K2 已经开始在产品中使用 Agentic RL，但仍面临上述四大挑战。

预期发展:

- **短期 (2026)**: 更多模型会在 Post-Training pipeline 中加入 Agentic RL 阶段
- **中期 (2027)**: Agentic RL 的算法和工程实践趋于成熟，形成类似 RLHF 当年的"标准 pipeline"
- **长期**: Agent 能力成为模型的标配，而非可选的额外能力

4.2 方向二：自我进化与自我改进

DeepSeek-R1 的 R1-Zero 实验暗示了一个激动人心的方向：**模型是否能通过 RL 实现真正的自我进化?**

当前的 RL 训练仍然依赖人类设计的奖励函数（即使是规则奖励也是人类定义的规则）。未来的方向可能包括：

- **自生成任务**: 模型自己提出问题、自己尝试解决、从成败中学习
- **环境交互学习**: 在真实（或模拟）环境中通过交互获得反馈
- **Meta-Learning**: 学会如何更高效地学习

4.3 方向三：统一的优化框架

SAPO 论文提出的统一视角（所有算法都是 $f(r) \cdot A$ 的形式）暗示了一个趋势：**从散乱的算法创新走向统一的理论框架**。

当前的算法演进（PPO → GRPO → DAPO → VAPO → CISPO → GSPO → SAPO）看起来是一系列独立的改进，但 SAPO 展示了它们之间的深层联系。未来可能出现一个**自适应框架**，根据任务特征自动选择最优的裁剪/门控策略。

4.4 方向四：高效训练

当前瓶颈	潜在解决方向
Rollout 占训练时间 60%+	投机解码加速采样、前缀共享（TreePo）
多模型同时在 GPU 上	异步 actor-critic、模型并行优化
蒸馏仍需从头 RL 训练教师	自动化蒸馏 pipeline
超参数敏感	自适应超参数调整（SAPO 的温度自适应是一个方向）

4.5 方向五：多模态 Post-Training

SAPO 已经应用于 Qwen3-VL（视觉语言模型），GLM-5 也是多模态模型。Post-Training 正在从纯文本扩展到多模态：

- **视觉推理**: 图表理解、几何题
- **代码生成**: IDE 交互、调试
- **工具使用**: 调用 API、操作界面
- **机器人**: 物理世界交互

每种模态都带来新的奖励设计和信用分配挑战。

五、个人观点与判断

观点 1：Value-Based 和 Value-Free 之争尚未终结

VAPO 证明了"修好 Critic 后 Value-Based 更强"，但 GSPO/SAPO 证明了"Value-Free 也能做到很好只要改进 IS 处理"。我的判断：

- **长 CoT 推理**（>1000 tokens）: Value-Based 可能更优，因为 GAE 能提供 token 级别的信用分配
- **短任务 + MoE 模型**: Value-Free (GSPO/SAPO) 更实用，因为 MoE 的 Critic 训练更困难
- **最终方向**: 可能是**自适应切换**——根据任务类型和序列长度动态选择

观点 2：算法创新的边际收益在递减

从 GRPO 到 DAPO 带来了巨大提升（+7 分 AIME），但从 GSPO 到 SAPO 的提升在收窄。**工程实践（数据质量、训练稳定性、超参数调优）的重要性正在超越算法本身**。

这不是说算法研究不重要——CISPO 解决梯度归零、GSPO 解决 MoE 稳定性都是关键突破。但对于大多数团队来说，把 DAPO/GRPO 跑好（高质量数据 + 稳定训练）可能比追逐最新算法更有价值。

观点 3：Agentic RL 是下一个"R1 时刻"的候选

DeepSeek-R1 证明了 RL 可以让推理能力涌现。类似地，Agentic RL 可能让**规划能力**、**工具使用能力**、**多步推理能力**从 RL 中涌现。EMPO² 的 +128.6% 提升已经初显端倪。

但 Agentic RL 比 Reasoning RL 难得多：

- 奖励更稀疏（多步交互后才有结果）
- 状态空间更大（包含外部环境）
- 评估更困难（没有像数学那样清晰的正确答案）

观点 4：Post-Training 的"秘密"不在论文里

阅读了大量技术报告后，一个深刻的体会是：**论文展示的是结果和方法，但真正的 know-how 在论文之外**。

例如：

- DeepSeek-R1 的 Cold Start SFT 数据是怎么构造的？论文没有详说
- LLaMA 3.1 的 6 轮迭代中，每轮具体改了什么？数据如何迭代？细节不多
- VAPO 的 Value Pretraining 为什么恰好 50 步？超参数是怎么选的？

这些"秘密"构成了各家的竞争壁垒。对于希望复现的团队来说，开源的算法代码（如 DAPO, veRL）是起点，但到达 SOTA 还需要大量的工程试错。

观点 5：Post-Training 正在成为"炼丹术"的新战场

Pre-Training 已经高度标准化（Transformer + 大规模数据 + 标准训练 recipe），Post-Training 正在成为各家差异化竞争的核心。

- **数据**: SFT/RL 的数据构造方法是最大的秘密
- **Pipeline 设计**: 阶段划分、顺序、数据分配
- **超参数**: 学习率、KL 系数、裁剪范围、Group Size...
- **算法选择**: PPO vs GRPO vs DPO，何时用哪个

这些选择的组合空间极大，而且**高度依赖具体的模型、数据和任务**。没有一个"万能配方"。

观点 6：关于"RL 是否真的在教模型推理"的思考

一个更深层的问题：RL 真的在**教**模型新的推理能力，还是仅仅在**选择**预训练中已经学到的能力？

支持"选择"的证据：

- R1-Zero 的推理能力在 RL 之前就以某种形式存在于基座模型中
- Qwen3 仅 170 步 RL 就大幅提升，说明能力已在
- Rejection Sampling（纯选择，无参数更新）就能显著提升性能

支持"教授"的证据：

- R1-Zero 涌现了基座模型从未在预训练数据中见过的行为（如 "aha moment"）
- ProRL 证明延长 RL 训练可以突破基座模型的推理边界
- 蒸馏的效果不如从头 RL，说明 RL 确实在做"额外的事"

我的判断：**两者兼有，但比例随训练时间变化**。RL 早期主要是"选择"（放大已有的好行为），后期逐渐转向"教授"（探索新的推理模式）。这也解释了为什么短期 RL 和蒸馏效果接近，但长期 RL 能超越蒸馏的天花板。

附录：四大核心挑战的关系图

```
                    ┌──────────────────┐
                    │  奖励信号质量     │ ← 源头问题
                    │  (68% 论文提及)   │
                    └──────────────────┘
                              │
                              │
            稀疏/噪声奖励导致方差爆炸
                              │
                    ┌─────────▼────────┐
        ┌───────────┤  训练稳定性       ├──────────┐
        │           │  (53% 论文提及)   │          │
        │           └──────────────────┘          │
        │                    │                    │
        │                    │                    │
   IS ratio 极端化     梯度方差爆炸         策略震荡
```

```
│                    │                    │
│          ┌─────────▼─────────┐          │
└──────────┤  信用分配         ├──────────┘
           │  （44% 论文提及）  │
           └───────────────────┘
                     │
                     │
           精确归因改善有效训练信号
                     │
           ┌─────────▼─────────┐
           │  探索效率         │ ← 受所有挑战制约
           │  （44% 论文提及）  │
           └───────────────────┘
```

关键洞察: 奖励信号是源头（稀疏/噪声导致方差爆炸），信用分配是桥梁（精确归因改善奖励质量），训练稳定性是保障（不稳定则无法有效训练），探索效率是最终目标（在有限计算资源下最大化学习效果）。

上一章: [第二章：技术报告解读与训练经验](#) | 返回: [总目录](#)