LLM Post-Training 技术报告

> ***作者***: *Zhen Liang*
> ***最后更新***: *2026-03-17*
> ***定位***: *面向有一定机器学习基础的读者，系统梳理大语言模型后训练（Post-Training）的算法原理、工业实践与未来方向*

报告结构

本报告共分三章，从算法原理到工业实践再到前沿展望，层层递进：

[第一章：算法与基本原理]

从大模型训练全景出发，深入 Post-Training 的两大范式与主流算法：

- **一、大模型训练全景** — Pre-Training / Mid-Training / Post-Training 三阶段概述与 2025 年趋势
- **二、Post-Training 两大范式：RLHF 与 RLVR** — 经典 RLHF 三阶段、RLVR 的崛起、两大范式对比与 2025 收敛趋势
- **三、DPO** — 离线偏好优化（简述）
- **四、PPO** — 经典策略优化基础（简述）
- **五、GRPO** — RLVR 的奠基算法：Value-Free + RM-Free 设计
- **六、DAPO** — 工业级 RLVR 工程优化（四大核心改进）
- **七、VAPO** — Value-Based 路线的回归与 Critic 修复
- **八、CISPO** — 裁剪 IS 权重而非目标函数
- **九、GSPO** — 序列级策略优化
- **十、SAPO** — 连续信任域的软门控
- **十一、全部算法公式速查表** — 含范式归属（RLHF / RLVR）
- **十二、演进逻辑总结**

[第二章：技术报告解读与训练经验]

聚焦 2025-2026 年主流大模型技术报告的深度解读，强调动机分析与技术洞察：

- **一、DeepSeek-R1** — 纯 RL 推理涌现、R1-Zero 实验、失败尝试的负面结果
- **二、DeepSeek-V3** — 高效后训练与 R1 蒸馏 Pipeline
- **三、Qwen3** — Thinking Mode Fusion 与四阶段 Pipeline
- **四、Kimi K1.5 / K2** — 从推理 Scaling 到 Agentic Post-Training
- **五、Seed1.5-Thinking** — DAPO/VAPO 工业规模验证与关键发现
- **六、LLaMA 3.1 / 4** — 从 DPO 到 Online RL 的转向
- **七、GLM-5** — 异步 Agent RL 与工程教训
- **八、Gemini 2.5** — 可验证奖励与思考预算
- **九、OpenAI o 系列** — RL 驱动的推理 Scaling
- **十、跨模型训练经验总结** — 9 条从实战中提炼的关键教训

[第三章：发展路线与方向思考]

技术演进的宏观分析与个人思考：

- **一、技术演进时间线** — 从 InstructGPT 到 Agentic RL 的三年关键里程碑

- **二、Post-Training 范式演变** — 四代范式（SFT-Only → RLHF → RLVR → Agentic RL）及其驱动力
- **三、核心技术挑战** — 奖励信号、训练稳定性、探索效率、信用分配
- **四、未来发展方向** — Agentic RL、自我进化、统一框架、高效训练、多模态
- **五、个人观点** — 6 条对当前热点问题的主观判断（💭 标记）

引用的核心论文

综述与基础

论文	arXiv ID	关键贡献
Mid-Training Survey	2510.23081	定义 Pre/Mid/Post 三阶段分类法
Post-Training Survey	2503.06072	全面梳理 Post-Training 方法
InstructGPT	—	确立 RLHF 三阶段范式（2022）
DPO	—	绕过 RM 的直接偏好优化（2023）

核心算法

算法	arXiv ID	范式	关键贡献
GRPO	—	RLVR	Value-Free + RM-Free，组间归一化
DAPO	2503.14476	RLVR	首个完全开源大规模 RL 系统，四大工程改进
VAPO	2504.05118	RLVR	跨分支融合，修复 Critic
CISPO	2506.13585	RLVR	裁剪 IS 权重保留梯度
GSPO	2507.18071	RLVR	Sequence-Level 优化
SAPO	2511.20347	RLVR	Soft Gating 替代 Hard Clipping
Dr. GRPO	2503.20783	RLVR	修正 GRPO 方差控制问题
REINFORCE++	2501.03262	RLVR	Token-level baseline + per-token KL
PRIME	2502.01456	RLVR	隐式过程奖励

技术报告

模型	arXiv ID	关键贡献
DeepSeek-R1	2501.12948	纯 RL 推理涌现，GRPO 大规模应用
DeepSeek-V3	2412.19437	R1 蒸馏 pipeline
Qwen3	2505.09388	Thinking Mode Fusion，强到弱蒸馏
Qwen2.5	2412.15115	四阶段 pipeline + 6 维 RM

Kimi K1.5	2501.12599	推理 Scaling 的简约路线
Kimi K2	2507.20534	Agentic 数据合成 + 自批评奖励
Seed1.5-Thinking	2504.13914	DAPO/VAPO 工业规模验证
LLaMA 3.1	2407.21783	6 轮迭代 Post-Training，DPO > PPO
GLM-5	2602.15763	五阶段全能 pipeline，异步 Agent RL
Gemma 3	2503.19786	权重平均与可验证奖励

阅读建议

- **快速了解全貌**: 阅读本 README + 第一章前两节（训练全景 + 两大范式）+ 第三章时间线
- **深入算法细节**: 第一章第五至十节（GRPO → SAPO 六大算法，含完整公式推导和 📖 初学者补充）
- **了解工业实践**: 第二章各模型解读 + 第十节跨模型经验总结
- **把握未来方向**: 第三章的范式演变 + 发展方向 + 个人观点（💭 标记）

本报告基于截至 2026 年 3 月的公开论文和技术博客撰写。